



Rapport de Projet de Data Warehouse

Filière : **Génie Logiciel**

Sujet :

Conception et Implémentation d'un Système Décisionnel Basé sur un Data Warehouse

---

Réalisé par :

BAHBAH Ikram
LABHAL Alae
LAMEGHAIZI Kawtar
REZGUANI Hiba

Encadré par :

Pr. FAKHOURI AMR
Meryem

Année Universitaire : 2025-2026

Remerciements

Nous tenons à exprimer nos sincères remerciements à notre professeur de Data Warehouse, **Pr. FAKHOURI AMR Meryem**, pour son accompagnement, son soutien constant et sa compréhension tout au long de la réalisation de ce projet.

Grâce à son encadrement pédagogique, à la clarté de ses orientations, à la pertinence de son plan de travail ainsi qu'à la structuration progressive des différentes étapes du projet, nous avons pu avancer de manière organisée, méthodique et efficace.

Nous lui sommes également reconnaissants pour la qualité des enseignements dispensés en Data Warehouse, qui nous ont permis de réaliser ce projet de manière fluide et structurée, en mettant en pratique les compétences acquises tout au long de la formation.

Ses remarques constructives, sa disponibilité et ses encouragements ont constitué une véritable source de motivation, nous aidant à surmonter les difficultés rencontrées et à mener ce travail à bien dans les meilleures conditions.

Résumé

Ce projet porte sur la conception et la mise en place d'un système décisionnel basé sur un Data Warehouse, destiné à l'analyse des performances d'une entreprise à partir de données de ventes. L'objectif principal est de centraliser, transformer et exploiter les données afin de faciliter la prise de décision stratégique.

Le projet s'appuie sur un processus ETL développé en Python pour l'extraction, le nettoyage et la transformation des données issues du dataset Superstore. Une modélisation multidimensionnelle a été réalisée à travers des schémas en étoile permettant d'organiser les données selon différents axes d'analyse tels que les ventes, les clients et la livraison.

Les données ont ensuite été exploitées à l'aide de Power BI pour la création de tableaux de bord interactifs, offrant une visualisation claire des indicateurs clés de performance (KPI).

En complément, une composante d'intelligence artificielle a été intégrée, incluant la prévision du chiffre d'affaires à court terme et la segmentation des clients par clustering, afin d'apporter une dimension analytique avancée.

Ce système permet ainsi d'améliorer la compréhension des données, d'optimiser les performances et de soutenir efficacement la prise de décision.

Mots-clés : Système décisionnel, Data Warehouse, ETL, Python, Power BI, Tableaux de bord interactifs, Indicateurs clés de performance, Intelligence artificielle.

Abstract

This project focuses on the design and implementation of a Business Intelligence system based on a Data Warehouse, aimed at analyzing company performance using sales data. The main objective is to centralize, transform, and exploit data in order to facilitate strategic decision-making.

The project relies on an ETL process developed in Python for data extraction, cleaning, and transformation from the Superstore dataset. A multidimensional model was designed using star schemas to organize data according to different analysis axes such as sales, customers, and shipping.

The data was then analyzed using Power BI to create interactive dashboards, providing a clear visualization of key performance indicators (KPIs).

In addition, an artificial intelligence component was integrated, including short-term revenue forecasting and customer segmentation using clustering techniques, in order to enhance the analytical dimension of the system.

This solution improves data understanding, optimizes performance, and effectively supports decision-making.

Keywords : Business Intelligence system, Data Warehouse, ETL, Python, Power BI, Interactive dashboards, Key performance indicators, Artificial intelligence.

Table des matières

Remerciements **2**

Résumé **3**

Abstract **4**

Introduction générale **10**

1 Contexte et Analyse des Données **11**
Introduction . . . 11
1.1 Contexte et Objectifs du projet . . . 11
1.1.1 Contexte . . . 11
1.1.2 Objectifs . . . 11
1.2 Présentation du dataset et description des colonnes . . . 12
1.2.1 Description des colonnes . . . 12
1.2.2 Caractéristiques des données . . . 12
1.3 Processus métier . . . 13
1.3.1 Ventes . . . 13
1.3.2 Clients . . . 13
1.3.3 Livraison . . . 13
1.3.4 Objectif global et impact stratégique . . . 14
Conclusion . . . 14

2 Data Warehouse et Processus ETL **15**
Introduction . . . 15
2.1 Processus ETL : Extraction, Transformation et Chargement . . . 15
2.1.1 Phase 1 : Extraction des données . . . 16
2.1.1.1 Importation des bibliothèques . . . 16
2.1.1.2 Chargement du dataset . . . 16
2.1.1.3 Analyse de la structure des données . . . 16
2.1.2 Phase 2 : Transformation des données . . . 17
2.1.2.1 Audit de qualité des données . . . 17
2.1.2.2 Gestion des valeurs manquantes . . . 18
2.1.2.3 Étape de nettoyage des données . . . 18
2.1.2.4 Analyse approfondie des doublons métier . . . 21
2.1.3 Phase 3 : Chargement des données (Loading) . . . 22
2.1.3.1 Création des tables dimensionnelles . . . 22
2.1.3.2 Création des tables de faits . . . 23
2.1.3.3 Conclusion de la phase de chargement . . . 24

2.2 Modélisation multidimensionnelle : Tables de faits, Dimensions, Schémas en étoile . . . 24
2.2.1 Processus Ventes . . . 24
2.2.1.1 Table de faits Ventes . . . 24
2.2.1.2 Tables de dimensions Ventes . . . 25
2.2.1.3 Schéma en étoile Ventes . . . 27
2.2.1.4 Indicateurs de performance clés (KPI) Ventes . . . 28
2.2.2 Processus Clients . . . 28
2.2.2.1 Table de faits Clients . . . 28
2.2.2.2 Tables de dimensions Clients . . . 29
2.2.2.3 Schéma en étoile Clients . . . 30
2.2.2.4 Indicateurs de performance clés (KPI) . . . 30
2.2.3 Processus Livraison . . . 31
2.2.3.1 Table de faits Livraison . . . 31
2.2.3.2 Tables de dimensions Livraison . . . 31
2.2.3.3 Schéma en étoile Livraison . . . 32
2.2.3.4 Indicateurs de performance clés (KPI) . . . 32
Conclusion . . . 32

3 Outils et Visualisation 33
Introduction . . . 33
3.1 Outils utilisés . . . 33
3.1.1 Python . . . 33
3.1.2 Power BI . . . 33
3.2 Création et analyse des dashboards Power BI . . . 34
3.2.1 Dashboard processus Ventes . . . 34
3.2.1.1 Dashboard 1 — Performances des produits et catégories . . . 35
3.2.1.2 Dashboard 2 — Tendances mensuelles des ventes . . . 36
3.2.1.3 Dashboard 3 — Tendances trimestrielles et panier moyen . . . 37
3.2.2 Dashboard processus Clients . . . 38
3.2.2.1 Dashboard 1 — Vue générale clients . . . 38
3.2.2.2 Dashboard 2 — Géographie clients . . . 39
3.2.2.3 Dashboard 3 — Tendances clients . . . 39
3.2.3 Dashboard processus Livraison . . . 40
Conclusion . . . 41

4 Intégration d'une Composante IA 42
Introduction . . . 42
4.1 Prévision des ventes (CA sur 3 mois) . . . 42
4.1.1 Analyse exploratoire des données . . . 42
4.1.2 Analyse de la tendance . . . 43
4.1.3 Création des variables explicatives (Feature Engineering) . . . 44
4.1.3.1 Division des données . . . 44
4.1.4 Modélisation avec Ridge Regression . . . 45
4.1.5 Évaluation du modèle . . . 45
4.1.5.1 Visualisation des prédictions . . . 46
4.1.6 Prévision des 3 prochains mois . . . 46
4.2 Segmentation des clients par clustering K-Means . . . 47
4.2.1 Agrégation des données par client . . . 47

4.2.2 Vérification des valeurs aberrantes 48
4.2.3 Normalisation des données 48
4.2.4 Détermination du nombre optimal de clusters 49
4.2.5 Application de l'algorithme K-Means 50
4.2.6 Analyse des clusters 50
4.2.7 Interprétation métier des segments 51
4.2.8 Visualisation des segments clients 51
4.2.8.1 Scatterplot : Segmentation des clients (Ventes vs Profit) . 52
4.2.8.2 Graphe en barres : Comparaison des segments 52
4.2.8.3 Diagramme circulaire : Répartition des segments 53
Conclusion 54

Conclusion Générale **55**

Table des figures

2.1 Importation des bibliothèques 16
2.2 Chargement du dataset 16
2.3 Analyse de la structure des données 17
2.4 Audit de qualité des données 17
2.5 Résultat de l'audit de qualité 18
2.6 Lignes avec code postal manquant 18
2.7 Renommage des colonnes 19
2.8 Conversion des dates en format datetime 19
2.9 Correction et formatage des codes postaux 20
2.10 Suppression des doublons 20
2.11 Analyse des doublons métier 21
2.12 Exemple de variations de prix dans une commande 21
2.13 Création de la dimension Date 22
2.14 Création de la dimension Ship Mode 23
2.15 Création de la dimension Customer 23
2.16 Création de la dimension Product 23
2.17 Création de la dimension Geography 23
2.18 Schéma en étoile du processus Ventes 27
2.19 Schéma en étoile du processus Clients 30
2.20 Schéma en étoile du processus Livraison 32

3.1 Logo de Python 33
3.2 Logo de Power BI 34
3.3 Dashboard 1 — Performances des produits et catégories 36
3.4 Dashboard 2 — Tendances mensuelles des ventes 37
3.5 Dashboard 3 — Tendances trimestrielles des ventes 38
3.6 Dashboard processus Clients 38
3.7 Dashboard 2 — Géographie clients 39
3.8 Dashboard 3 — Tendances clients 40
3.9 Dashboard du processus Livraison 41

4.1 Statistiques descriptives du dataset 43
4.2 Tendance des ventes avec régression linéaire 43
4.3 Comparaison des ventes réelles et prédites (Ridge) 46
4.4 Prévision des ventes sur les 3 prochains mois 47
4.5 Détection des valeurs aberrantes pour TotalSales, TotalProfit et TotalQuantity 48
4.6 Méthode du coude pour déterminer le nombre optimal de clusters 49
4.7 Moyennes des indicateurs par cluster 51

4.8 Segmentation des clients (Ventes vs Profit) 52
4.9 Comparaison des segments selon les indicateurs clés 52
4.10 Répartition des segments clients 53

Introduction générale

Dans le cadre de notre formation en Génie Logiciel, nous avons réalisé un projet visant à mettre en place un système décisionnel basé sur un Data Warehouse pour le suivi des performances d'une entreprise. Dans un contexte où les organisations génèrent un volume important de données issues de différentes sources, il devient essentiel de disposer d'outils permettant de centraliser, analyser et exploiter ces données de manière efficace afin de faciliter la prise de décision.

L'entreprise étudiée dispose de données relatives aux ventes, aux clients et aux livraisons, mais celles-ci sont souvent dispersées et difficilement exploitables sous forme brute. Cette situation limite la capacité des décideurs à obtenir une vision globale et cohérente de l'activité, à identifier les tendances clés et à suivre les indicateurs de performance de manière fiable et rapide.

Face à ces enjeux, notre projet consiste à concevoir et implémenter un Data Warehouse permettant de centraliser les données issues du système opérationnel, puis à développer un tableau de bord interactif offrant une visualisation claire et dynamique des indicateurs clés de performance (KPI). Ce système permet notamment d'analyser les ventes, le comportement des clients et l'efficacité des livraisons, tout en facilitant l'exploration des données à travers des graphiques et des filtres interactifs.

En complément, une composante d'intelligence artificielle a été intégrée afin d'apporter une dimension prédictive et analytique au projet. Cette composante inclut la prévision du chiffre d'affaires à court terme ainsi que la segmentation des clients à l'aide d'algorithmes de machine learning, permettant ainsi d'anticiper les tendances futures et d'optimiser les stratégies commerciales.

Le rapport est structuré en plusieurs chapitres. Le premier chapitre présente le cadrage général du projet, incluant le contexte, la problématique et les objectifs. Le deuxième chapitre est consacré à la conception du Data Warehouse et aux processus ETL. Le troisième chapitre décrit la mise en place du tableau de bord interactif et l'analyse des indicateurs. Enfin, le dernier chapitre porte sur l'intégration de la composante d'intelligence artificielle, incluant la prévision des ventes et la segmentation des clients.

Chapitre 1

Contexte et Analyse des Données

Introduction

Ce chapitre présente le contexte général du projet de mise en place d'un système décisionnel basé sur un Data Warehouse. Il introduit les objectifs visés, le dataset utilisé ainsi que le processus métier adopté. L'objectif est de poser les bases nécessaires pour la compréhension des étapes suivantes du projet.

1.1 Contexte et Objectifs du projet

1.1.1 Contexte

Les entreprises s'appuient de plus en plus sur les données pour améliorer leur performance et optimiser leur prise de décision. Cependant, les données sont souvent dispersées et difficiles à exploiter directement.

Dans ce contexte, les systèmes décisionnels, notamment les Data Warehouses, permettent de centraliser et structurer les données afin de faciliter leur analyse. L'utilisation de tableaux de bord interactifs offre une vision claire et synthétique des performances de l'entreprise.

Ce projet s'inscrit dans cette démarche en proposant une solution permettant de suivre et analyser les données de ventes.

1.1.2 Objectifs

L'objectif principal de ce projet est de concevoir un système décisionnel permettant d'exploiter les données de manière efficace.

Les objectifs spécifiques sont les suivants :

- Mettre en place un Data Warehouse pour centraliser les données
- Suivre les indicateurs de performance de l'entreprise
- Faciliter l'analyse des données selon différents axes
- Améliorer la visibilité globale sur l'activité commerciale
- Aider à la prise de décision

1.2 Présentation du dataset et description des colonnes

Le dataset utilisé pour ce projet provient de la base **Superstore Dataset** disponible sur Kaggle : https://www.kaggle.com/datasets/vivek468/superstore-dataset-final.

Il regroupe des informations détaillées sur les transactions commerciales d'une entreprise de type superstore, c'est-à-dire un grand magasin combinant plusieurs catégories de produits. Cette entreprise est située aux **États-Unis** et son activité principale consiste à vendre du mobilier de bureau, des fournitures de bureau et des produits technologiques à des clients variés, incluant les particuliers (Consumer), les entreprises (Corporate) et les bureaux à domicile (Home Office).

Chaque enregistrement du dataset correspond à une transaction unique, incluant les informations sur le client, le produit acheté, la date de commande, le mode de livraison, le montant de la vente, ainsi que le profit généré. Ces informations permettent de réaliser des analyses détaillées sur les ventes, le comportement des clients, et les performances des produits.

1.2.1 Description des colonnes

Colonne	Description
Row ID	Identifiant unique de l'enregistrement
Order ID	Identifiant unique de la commande
Order Date	Date à laquelle la commande a été passée
Ship Date	Date à laquelle la commande a été expédiée
Ship Mode	Mode de livraison (Standard, Express, etc.)
Customer ID	Identifiant unique du client
Customer Name	Nom du client
Segment	Type de client (Consumer, Corporate, Home Office)
Country	Pays du client
City	Ville du client
State	État ou région
Postal Code	Code postal
Region	Zone géographique (Ouest, Est, Sud, Centre)
Product ID	Identifiant unique du produit
Category	Catégorie du produit (Furniture, Office Supplies, Technology)
Sub-Category	Sous-catégorie du produit
Product Name	Nom du produit
Sales	Montant des ventes (en dollars)
Quantity	Quantité vendue
Discount	Taux de remise appliqué (%)
Profit	Profit généré par la transaction (en dollars)

Table 1.1 – Description des colonnes du dataset

1.2.2 Caractéristiques des données

- **Données transactionnelles** : Chaque ligne correspond à une vente unique.
- **Données temporelles** : Contient les dates de commande et d'expédition, ce qui permet d'analyser les tendances dans le temps.

- **Données géographiques** : Informations sur le pays, l'état, la ville et la région pour une analyse spatiale des ventes.
- **Données clients et produits** : Permet d'analyser le comportement des clients et la performance des produits et catégories.
- **Données financières** : Les colonnes Sales, Discount et Profit permettent d'évaluer la rentabilité et l'efficacité des ventes.

1.3 Processus métier

Dans le cadre de ce projet, l'objectif principal est d'analyser les processus clés de l'entreprise afin de fournir des informations pertinentes pour la prise de décision stratégique et l'amélioration globale des performances. Les processus identifiés comme prioritaires pour cette analyse sont : les ventes, les clients et la livraison. Chacun de ces processus joue un rôle crucial dans le fonctionnement de l'entreprise et dans l'atteinte de ses objectifs commerciaux.

1.3.1 Ventes

Le processus de vente constitue le cœur de l'activité commerciale. L'analyse des ventes permet d'examiner en détail les produits les plus vendus ainsi que ceux qui sont moins performants, afin d'optimiser le catalogue et mieux répondre à la demande. Elle permet également d'identifier les tendances saisonnières et les périodes de forte ou faible activité, ce qui aide à anticiper les besoins et à planifier les ressources. L'efficacité des promotions et des remises appliquées est également évaluée pour mesurer leur impact sur le chiffre d'affaires, tandis que la rentabilité de chaque transaction et de chaque catégorie de produits est analysée afin d'optimiser la marge et la performance globale.

1.3.2 Clients

L'étude des clients permet de mieux comprendre le comportement des différentes catégories de clientèle, notamment les particuliers (Consumer), les entreprises (Corporate) et les bureaux à domicile (Home Office). Cette analyse inclut l'identification des clients à forte valeur et des clients réguliers, la segmentation de la clientèle selon leurs besoins et habitudes d'achat, ainsi que l'évaluation de la fidélité et de la satisfaction des clients. Elle permet également de détecter de nouvelles opportunités de marché et d'adapter les stratégies marketing pour mieux répondre aux besoins de chaque segment.

1.3.3 Livraison

Le processus de livraison est essentiel pour garantir la satisfaction client et maintenir la qualité du service. L'analyse du processus permet d'évaluer l'efficacité des différents modes de livraison, d'identifier les retards ou problèmes logistiques, et d'optimiser les délais ainsi que les coûts d'expédition. Elle aide également à mesurer l'impact de la livraison sur l'expérience client et la fidélisation, contribuant ainsi à améliorer la réputation et la performance opérationnelle de l'entreprise.

1.3.4 Objectif global et impact stratégique

L'analyse combinée de ces trois processus principaux – ventes, clients et livraison – permet à l'entreprise :

- D'améliorer ses performances commerciales en identifiant les opportunités de croissance
- De mieux comprendre le comportement et les besoins de sa clientèle
- D'optimiser la logistique, les délais et la qualité du service
- De prendre des décisions stratégiques basées sur des données fiables et pertinentes
- D'accroître la compétitivité de l'entreprise sur le marché
- D'anticiper les tendances et d'adapter les stratégies futures en conséquence

Ainsi, ce focus sur les processus clés permet non seulement de mesurer la performance actuelle, mais également de mettre en place des actions concrètes pour améliorer la rentabilité, la satisfaction client et l'efficacité opérationnelle de l'entreprise.

Conclusion

Ce chapitre a présenté le contexte du projet, les objectifs ainsi que les données utilisées. Il a également décrit le processus métier. Ces éléments constituent une base solide pour la conception du Data Warehouse et la réalisation des analyses dans les chapitres suivants.

Chapitre 2

Data Warehouse et Processus ETL

Introduction

Ce chapitre présente l'architecture du Data Warehouse conçu pour l'entreprise ainsi que les processus ETL permettant l'extraction, la transformation et le chargement des données. Il détaille également la structure des tables de faits et de dimensions, ainsi que la conception des schémas en étoile pour chaque processus clé.

2.1 Processus ETL : Extraction, Transformation et Chargement

Cette section sera développée ultérieurement. Elle décrira le flux ETL complet pour l'extraction, la transformation et le chargement des données dans le Data Warehouse.

Dans le cadre de la construction du Data Warehouse, un processus ETL (Extraction, Transformation, Loading) a été mis en place afin de préparer les données pour l'analyse décisionnelle.

Le processus ETL a été développé en Python en utilisant principalement la bibliothèque **Pandas**, permettant la manipulation efficace des données tabulaires.

2.1.1 Phase 1 : Extraction des données

La phase d'extraction consiste à récupérer les données brutes depuis le fichier source afin de les charger dans l'environnement de travail.

2.1.1.1 Importation des bibliothèques

Dans cette première étape, les bibliothèques nécessaires sont importées.

- Pandas : manipulation des données
- NumPy : calcul numérique
- Matplotlib : visualisation
- Datetime : gestion des dates

Script utilisé :

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import os, warnings
warnings.filterwarnings('ignore')
pd.set_option('display.max_columns', None)
pd.set_option('display.max_colwidth', 60)
print(' Librairies importées')

✓ 2.7s

Librairies importées
```

FIGURE 2.1 – Importation des bibliothèques

2.1.1.2 Chargement du dataset

Le fichier CSV contenant les données commerciales est chargé dans un DataFrame.
Script utilisé :

```
RAW_PATH = 'train.csv'
OUT_DIR  = 'dwh_output'
os.makedirs(OUT_DIR, exist_ok=True)

raw = pd.read_csv(RAW_PATH, encoding='utf-8', on_bad_lines='skip')
```

FIGURE 2.2 – Chargement du dataset

2.1.1.3 Analyse de la structure des données

Une analyse de la structure du dataset est effectuée afin d'identifier le nombre de lignes et colonnes.

```python
raw = pd.read_csv(RAW_PATH, encoding='utf-8', on_bad_lines='skip')
print(f'Dimensions brutes : {raw.shape[0]:,} lignes x {raw.shape[1]} colonnes')
print(f'Colonnes : {list(raw.columns)}')
raw.head(3)
```

Python

```
Dimensions brutes : 9,800 lignes x 18 colonnes
Colonnes : ['Row ID', 'Order ID', 'Order Date', 'Ship Date', 'Ship Mode', 'Customer ID', 'Customer Name', 'Segmen
```

	Row ID	Order ID	Order Date	Ship Date	Ship Mode	Customer ID	Customer Name	Segment	Country	City	State
0	1	CA-2017-152156	08/11/2017	11/11/2017	Second Class	CG-12520	Claire Gute	Consumer	United States	Henderson	Kentucky
1	2	CA-2017-152156	08/11/2017	11/11/2017	Second Class	CG-12520	Claire Gute	Consumer	United States	Henderson	Kentucky
2	3	CA-2017-138688	12/06/2017	16/06/2017	Second Class	DV-13045	Darrin Van Huff	Corporate	United States	Los Angeles	California

FIGURE 2.3 – Analyse de la structure des données

2.1.2 Phase 2 : Transformation des données

La phase de transformation consiste à nettoyer et préparer les données afin de garantir leur qualité et leur cohérence.

2.1.2.1 Audit de qualité des données

Un audit des données est réalisé pour détecter les anomalies.

```python
print('=== AUDIT QUALITÉ ===')
print('\n-- Types --')
print(raw.dtypes.to_string())
print('\n-- Valeurs manquantes --')
nulls = raw.isnull().sum()
print(nulls[nulls > 0].to_string() if nulls.sum() > 0 else 'Aucune')
print(f'\n-- Doublons entiers : {raw.duplicated().sum()} --')
print(f'-- Row ID unique : {raw["Row ID"].nunique()} / {len(raw)} (grain = 1 ligne de vente) --')
print(f'-- Sales min={raw["Sales"].min():.2f}  max={raw["Sales"].max():.2f}  negatifs={(raw["Sales"]<0).sum()} --')
day_max = raw['Order Date'].str.split('/').str[0].astype(int).max()
print(f'-- Format dates : premier segment max = {day_max} -> DD/MM/YYYY --')
# Product ID avec plusieurs noms
multi_name = (raw.groupby('Product ID')['Product Name'].nunique() > 1).sum()
print(f'-- Product ID avec plusieurs noms : {multi_name} (seront dedupliques) --')
# Postal code nulls
print(f'-- Postal Code manquants : {raw["Postal Code"].isnull().sum()} (Burlington VT -> 05401) --')
```

Python

FIGURE 2.4 – Audit de qualité des données

Cette étape permet d'identifier :

- Valeurs manquantes
- Doublons
- Colonnes problématiques

```
=== AUDIT QUALITÉ ===

-- Types --
Row ID             int64
Order ID          object
Order Date        object
Ship Date         object
Ship Mode         object
Customer ID       object
Customer Name     object
Segment           object
Country           object
City              object
State             object
Postal Code      float64
Region            object
Product ID        object
Category          object
Sub-Category      object
Product Name      object
Sales            float64

-- Valeurs manquantes --
Postal Code    11

-- Doublons entiers : 0 --
-- Row ID unique : 9800 / 9800 (grain = 1 ligne de vente) --
-- Sales min=0.44  max=22638.48  negatifs=0 --
-- Format dates : premier segment max = 31 -> DD/MM/YYYY --
-- Product ID avec plusieurs noms : 32 (seront dedupliques) --
-- Postal Code manquants : 11 (Burlington VT -> 05401) --
```

Figure 2.5 – Résultat de l'audit de qualité

2.1.2.2 Gestion des valeurs manquantes

Les valeurs manquantes dans les codes postaux ont été identifiées et corrigées.

```python
# Lister les lignes avec des codes postaux manquants
postal_code_nulls = raw[raw['Postal Code'].isnull()]

# Afficher toutes les colonnes pertinentes pour ces lignes
print("=== LIGNES AVEC CODE POSTAL MANQUANT ===")
print(f"Nombre de lignes : {len(postal_code_nulls)}")
print("\n")

# Afficher les détails complets
print(postal_code_nulls.to_string())

# Ou pour un affichage plus structuré avec les colonnes clés
print("\n=== DÉTAILS PAR LIGNE ===")
for idx, row in postal_code_nulls.iterrows():
    print(f"Ligne {idx} :")
    print(f"  - Order ID: {row['Order ID']}")
    print(f"  - Customer: {row['Customer Name']} ({row['Customer ID']})")
    print(f"  - City: {row['City']}")
    print(f"  - State: {row['State']}")
    print(f"  - Region: {row['Region']}")
    print(f"  - Postal Code: {row['Postal Code']} (MANQUANT)")
    print(f"  - Product: {row['Product Name']}")
    print(f"  - Sales: {row['Sales']}")

# Vérifier que ce sont bien toutes des lignes de Burlington, VT
print("\n=== RÉPARTITION PAR VILLE/ÉTAT ===")
print(postal_code_nulls.groupby(['City', 'State']).size())
```

Python

Figure 2.6 – Lignes avec code postal manquant

2.1.2.3 Étape de nettoyage des données

Après l'identification des valeurs manquantes, une phase complète de nettoyage des données a été réalisée afin d'assurer la cohérence et la qualité des informations avant la création des dimensions.

Cette étape comprend plusieurs opérations essentielles appliquées sur une copie du dataset original.

Renommage des colonnes Les colonnes ont été renommées afin d'utiliser une nomenclature standardisée, facilitant la manipulation et la compréhension des données.

- Uniformisation des noms des colonnes
- Utilisation d'une notation en minuscules
- Remplacement des espaces par des underscores

Résultat du renommage :

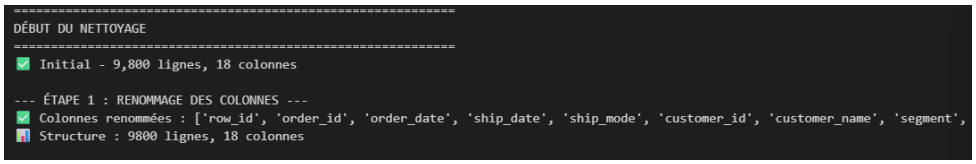


Figure 2.7 – Renommage des colonnes

Conversion des formats de dates Les colonnes contenant les dates ont été converties en format **datetime** afin de permettre des traitements temporels fiables.

Les contrôles réalisés incluent :

- Vérification du type avant conversion
- Conversion en format datetime
- Vérification des dates invalides
- Analyse de la période temporelle couverte

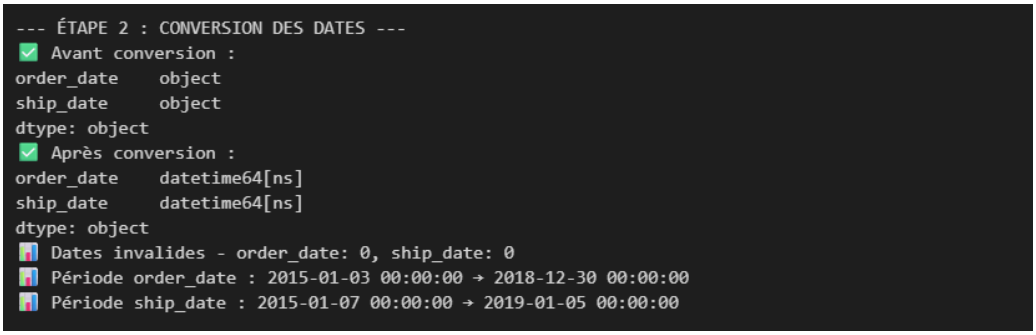


Figure 2.8 – Conversion des dates en format datetime

Les résultats obtenus montrent qu'aucune date invalide n'a été détectée et que la période des données s'étend de **2015 à 2019**.

Traitement des codes postaux Les valeurs manquantes dans la colonne **postal_code** ont été corrigées après analyse des villes correspondantes.

Dans le cas spécifique de la ville **Burlington**, toutes les lignes manquantes ont été remplacées par le code postal approprié.

Les étapes réalisées sont :

- Remplacement des valeurs nulles
- Attribution du code postal correct
- Formatage sur 5 chiffres

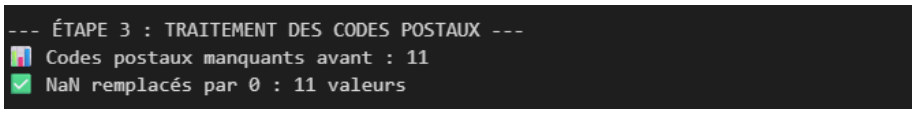


FIGURE 2.9 – Correction et formatage des codes postaux

Nettoyage des chaînes de caractères Afin d'éviter les erreurs liées aux espaces inutiles, toutes les chaînes de caractères ont été nettoyées.

Les opérations effectuées sont :

- Suppression des espaces en début et fin de texte
- Vérification des valeurs vides
- Standardisation des champs textuels

Cette étape garantit la cohérence des valeurs textuelles.

Suppression des doublons Une analyse des doublons a été réalisée afin d'identifier les transactions répétées.

Deux types de doublons ont été étudiés :

- Doublons complets
- Doublons basés sur la clé métier (order_id, product_id)

Après analyse, les doublons complets ont été supprimés afin d'éviter la redondance des données.

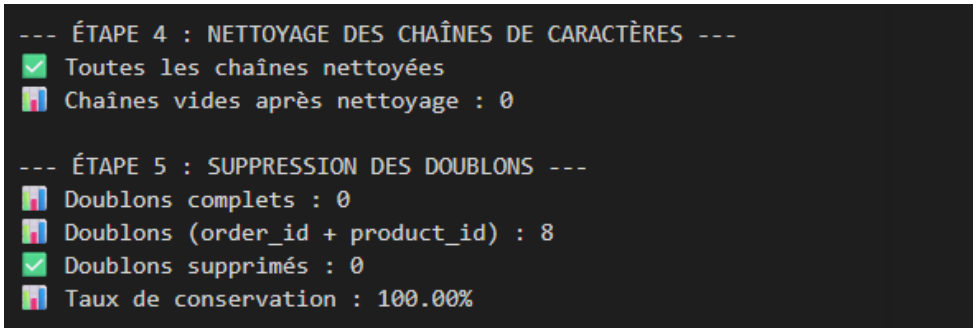


FIGURE 2.10 – Suppression des doublons

Vérifications finales de cohérence Après le nettoyage, plusieurs vérifications ont été effectuées pour garantir la qualité finale des données.

Les contrôles réalisés incluent :

- Vérification des ventes négatives
- Validation des dates de livraison
- Contrôle des identifiants uniques
- Vérification de l'absence de valeurs manquantes

Le nettoyage s'est terminé avec un dataset contenant :

- **9800 lignes propres**
- **18 colonnes**
- **Aucune valeur manquante restante**

2.1.2.4 Analyse approfondie des doublons métier

Une analyse détaillée a été réalisée sur les combinaisons **(order_id, product_id)** afin d'identifier d'éventuelles incohérences.

Cette analyse a permis d'identifier des cas où un même produit apparaît plusieurs fois dans une même commande avec des montants différents.

Identification des doublons métier Les combinaisons répétées ont été identifiées afin d'évaluer leur impact sur la qualité des données.

```
=== ANALYSE DES DOUBLONS (order_id + product_id) ===

📊 Nombre de combinaisons (order_id, product_id) avec doublons : 8
📊 Total des lignes concernées : 16
📊 Doublons à supprimer si on dédoublonne : 8

=== DÉTAIL DES LIGNES CONCERNÉES ===

🔍 Combinaison 1722 : CA-2016-103135 / OFF-BI-10000069 (2 occurrences)
   - Row ID: 6499, Product: GBC Prepunched Paper, 19-Hole, for Binding Systems..., Sales: 135.09, Quantity: 1
   - Row ID: 6501, Product: GBC Prepunched Paper, 19-Hole, for Binding Systems..., Sales: 90.06, Quantity: 1
   ℹ️  Ventes différentes : 2 valeurs uniques
```

Figure 2.11 – Analyse des doublons métier

Analyse des variations de prix Certains cas ont montré des différences de prix pour un même produit dans une même commande.

Après analyse, ces variations peuvent être expliquées par :

- L'application de remises commerciales
- La présence de quantités multiples
- Des ajustements manuels dans les commandes

```
42  ================================================================================
43
44  🔍 ANALYSE GÉNÉRALE : Pourquoi des prix différents pour le même produit ?
45
46
47  📋 Commande: CA-2016-103135
48     Produit: OFF-BI-10000069
49     Nom: GBC Prepunched Paper, 19-Hole, for Binding Systems, 24-lb...
50
51     --- Ligne 6499 ---
52     Sales: $135.09
53     Order Date: 2016-07-24 00:00:00
54     Ship Mode: Standard Class
55     Customer: Shirley Schmidt
56
57     --- Ligne 6501 ---
58     Sales: $90.06
59     Order Date: 2016-07-24 00:00:00
60     Ship Mode: Standard Class
61     Customer: Shirley Schmidt
62
63     🔎 ANALYSE:
64        - 💡 HYPOTHÈSE : Remise appliquée sur une partie de la commande
65        - 💡 HYPOTHÈSE : Erreur de saisie ou ajustement manuel
```

Figure 2.12 – Exemple de variations de prix dans une commande

Cette analyse confirme que ces occurrences ne représentent pas des erreurs de données mais des situations métier valides.

Ainsi, seules les lignes strictement identiques ont été supprimées.

2.1.3 Phase 3 : Chargement des données (Loading)

Après la phase de transformation et de nettoyage des données, une étape de chargement a été réalisée afin de construire physiquement les tables dimensionnelles et les tables de faits du Data Warehouse conformément au modèle en étoile défini lors de la phase de modélisation multidimensionnelle (section précédente).

Contrairement à la phase de modélisation, qui définit la structure logique des tables (dimensions, faits, relations et granularité), cette phase vise à matérialiser ces structures dans l'entrepôt de données et à alimenter chaque table avec les données transformées.

Cette étape comprend principalement :

- La création des tables dimensionnelles
- La génération des clés substituts (surrogate keys)
- L'établissement des relations entre les tables
- La création des tables de faits
- Le chargement des données finales dans le Data Warehouse

2.1.3.1 Création des tables dimensionnelles

Les tables dimensionnelles ont été générées à partir des données nettoyées lors des phases précédentes. Leur structure détaillée (colonnes, types et hiérarchies) a été définie lors de la phase de modélisation multidimensionnelle.

Dans cette phase, l'objectif principal était d'instancier ces dimensions et d'y insérer les données correspondantes.

Les opérations réalisées incluent :

- Extraction des valeurs distinctes pour chaque dimension
- Génération des clés substituts pour assurer l'unicité des enregistrements
- Respect du grain défini pour chaque dimension
- Tri et normalisation des données afin d'assurer la cohérence

Les dimensions créées sont :

- **DIM_DATE** : générée à partir des dates de commande et de livraison
- **DIM_SHIPMODE** : construite à partir des modes d'expédition
- **DIM_CUSTOMER** : regroupant les informations relatives aux clients
- **DIM_PRODUCT** : contenant les informations relatives aux produits
- **DIM_GEOGRAPHY** : décrivant la localisation géographique

Les figures suivantes illustrent les résultats obtenus après la création des différentes dimensions.

✅ Dim_Date : 1431 lignes | PK: date_key (INT YYYYMMDD)

	date_key	full_date	day	day_name	week	month	month_name	quarter	year	is_weekend
0	20150103	2015-01-03	3	Saturday	1	1	January	1	2015	1
1	20150104	2015-01-04	4	Sunday	1	1	January	1	2015	1
2	20150105	2015-01-05	5	Monday	2	1	January	1	2015	0

Figure 2.13 – Création de la dimension Date

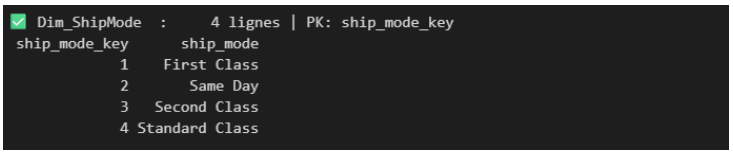


Figure 2.14 – Création de la dimension Ship Mode

Dim_Customer : 793 lignes | PK: customer_key | NK: customer_id

	customer_key	customer_id	customer_name	segment
0	1	AA-10315	Alex Avila	Consumer
1	2	AA-10375	Allen Armold	Consumer
2	3	AA-10480	Andrew Allen	Consumer

Figure 2.15 – Création de la dimension Customer

Dim_Product : 1861 lignes | PK: product_key | NK: product_id

	product_key	product_id	product_name	category	sub_category
0	1	FUR-BO-10000112	Bush Birmingham Collection Bookcase, Dark Cherry	Furniture	Bookcases
1	2	FUR-BO-10000330	Sauder Camden County Barrister Bookcase, Planked Cherry ...	Furniture	Bookcases
2	3	FUR-BO-10000362	Sauder Inglewood Library Bookcases	Furniture	Bookcases

Figure 2.16 – Création de la dimension Product

Dim_Geography : 600 lignes | PK: geo_key | Grain: City+State

	geo_key	city	state	postal_code	region	country
0	1	Auburn	Alabama	36830	South	United States
1	2	Decatur	Alabama	35601	South	United States
2	3	Florence	Alabama	35630	South	United States

Figure 2.17 – Création de la dimension Geography

2.1.3.2 Création des tables de faits

Après la création des dimensions, les tables de faits ont été construites en reliant les données transactionnelles aux différentes dimensions à l'aide des clés étrangères générées précédemment.

La structure détaillée des tables de faits ainsi que leur granularité ont été définies lors de la phase de modélisation multidimensionnelle.

Les principales opérations réalisées sont :

- Association des clés produits (*product_key*)
- Association des clés clients (*customer_key*)

- Association des clés géographiques (*geo_key*)
- Association des clés modes de livraison (*ship_mode_key*)
- Génération des clés temporelles (*order_date_key* et *ship_date_key*)
- Sélection des mesures métiers à intégrer dans les tables de faits

Trois tables de faits ont été créées dans le Data Warehouse :

- **FACT_SALES** : représentant les transactions commerciales
- **FACT_MODE_SHIP_DWH** : représentant les informations liées aux livraisons
- **FACT_CUSTOMER_PREF** : représentant les performances liées aux clients

2.1.3.3 Conclusion de la phase de chargement

La phase de chargement a permis de matérialiser l'ensemble des tables dimensionnelles et des tables de faits constituant le Data Warehouse final.

Les tables générées respectent la structure logique définie lors de la phase de modélisation multidimensionnelle et permettent une exploitation efficace des données dans les outils d'analyse décisionnelle tels que Power BI.

Cette étape constitue la dernière phase du processus ETL et prépare les données pour leur utilisation dans les tableaux de bord analytiques.

2.2 Modélisation multidimensionnelle : Tables de faits, Dimensions, Schémas en étoile

2.2.1 Processus Ventes

Le processus Ventes constitue le noyau principal du système décisionnel. Il permet d'analyser les transactions commerciales selon plusieurs axes analytiques tels que le produit, le client, la localisation géographique et le temps.

La modélisation multidimensionnelle adoptée repose sur un schéma en étoile, avec une table de faits centrale représentant les transactions de vente et plusieurs tables de dimensions décrivant les différents contextes d'analyse.

2.2.1.1 Table de faits Ventes

La table de faits centrale du processus Ventes est `FACT_SALES_DWH`. Elle contient les mesures quantitatives relatives aux ventes ainsi que les clés étrangères reliant les différentes dimensions.

Chaque ligne de cette table correspond à une ligne de commande associée à un produit donné, pour un client donné, à une date spécifique.

Table 2.1 – Structure de la table de faits `FACT_SALES_DWH`

Colonne	Type	Description
`sales_key`	INT (PK)	Identifiant unique de la ligne de vente
`order_id`	VARCHAR	Identifiant métier de la commande
`order_date_key`	INT (FK)	Référence vers `DIM_DATE` (date commande)
`ship_date_key`	INT (FK)	Référence vers `DIM_DATE` (date livraison)
`product_key`	INT (FK)	Référence vers `DIM_PRODUCT`
`customer_key`	INT (FK)	Référence vers `DIM_CUSTOMER`
`geo_key`	INT (FK)	Référence vers `DIM_GEOGRAPHY`
`ship_mode_key`	INT (FK)	Référence vers `DIM_SHIPMODE`
`sales`	FLOAT	Montant des ventes

La granularité de cette table correspond au niveau *ligne de commande — produit — client — date*.

2.2.1.2 Tables de dimensions Ventes

Le processus Ventes s'appuie sur plusieurs tables de dimensions permettant d'analyser les transactions commerciales selon différents axes analytiques tels que le produit, le client, la localisation géographique, le temps et le mode d'expédition.

DIM_PRODUCT La dimension produit regroupe les informations descriptives relatives aux produits vendus. Elle permet l'analyse des ventes selon une hiérarchie naturelle composée de trois niveaux : *Catégorie* → *Sous-catégorie* → *Produit*.

Cette hiérarchie facilite les analyses hiérarchiques dans Power BI, notamment les opérations de *drill-down*, permettant de passer d'une vue globale par catégorie à une vue détaillée par produit.

Table 2.2 – Structure de la table de dimension `DIM_PRODUCT`

Colonne	Type	Description
`product_key`	INT (PK)	Clé surrogate générée par le DW
`product_id`	VARCHAR	Identifiant métier du produit
`product_name`	VARCHAR	Nom du produit
`category`	VARCHAR	Catégorie principale du produit
`sub_category`	VARCHAR	Sous-catégorie du produit

DIM_CUSTOMER La dimension client contient les informations descriptives des clients ayant effectué des commandes. Elle permet d'analyser les ventes selon les segments commerciaux.

La clé surrogate `customer_key` est utilisée afin de dissocier l'identifiant métier `customer_id` du système source, ce qui assure la stabilité du modèle dimensionnel.

Table 2.3 – Structure de la table de dimension `DIM_CUSTOMER`

Colonne	Type	Description
`customer_key`	INT (PK)	Clé surrogate générée par le DW
`customer_id`	VARCHAR	Identifiant métier du client
`customer_name`	VARCHAR	Nom complet du client
`segment`	VARCHAR	Segment client (Consumer, Corporate, Home Office)

DIM_GEOGRAPHY La dimension géographique modélise la localisation des ventes selon une hiérarchie naturelle : *Pays* → *Région* → *État* → *Ville* → *Code postal*.

La granularité de cette dimension est définie au niveau du couple *Ville* + *État*, conformément aux données sources. Elle permet d'effectuer des analyses géographiques détaillées et de réaliser des visualisations cartographiques dans Power BI.

Table 2.4 – Structure de la table de dimension `DIM_GEOGRAPHY`

Colonne	Type	Description
`geo_key`	INT (PK)	Clé surrogate générée par le DW
`city`	VARCHAR	Ville
`state`	VARCHAR	État
`postal_code`	VARCHAR	Code postal
`region`	VARCHAR	Région géographique
`country`	VARCHAR	Pays

DIM_DATE La dimension temporelle est construite à partir des colonnes `order_date` et `ship_date` présentes dans les données sources.

Elle joue le rôle d'une *dimension à rôles multiples*, car la table de faits utilise deux clés étrangères distinctes (`order_date_key` et `ship_date_key`). Cela permet d'analyser les ventes aussi bien selon la date de commande que selon la date d'expédition.

Cette dimension contient plusieurs niveaux temporels permettant des analyses hiérarchiques telles que : *Année* → *Trimestre* → *Mois* → *Jour*.

Table 2.5 – Structure de la table de dimension `DIM_DATE`

Colonne	Type	Description
`date_key`	INT (PK)	Clé surrogate au format YYYYMMDD
`full_date`	DATE	Date complète
`day`	INT	Jour du mois
`day_name`	VARCHAR	Nom du jour
`week`	INT	Numéro de semaine
`month`	INT	Numéro du mois
`month_name`	VARCHAR	Nom du mois
`quarter`	INT	Trimestre
`year`	INT	Année
`is_weekend`	INT	Indicateur week-end (0 ou 1)

DIM_SHIPMODE La dimension mode d'expédition contient les différents types de livraison utilisés pour transporter les commandes. Elle permet d'analyser les ventes et les performances logistiques selon le mode d'expédition choisi.

Table 2.6 – Structure de la table de dimension `DIM_SHIPMODE`

Colonne	Type	Description
`ship_mode_key`	INT (PK)	Clé surrogate générée par le DW
`ship_mode`	VARCHAR	Mode d'expédition (Standard, Express, etc.)

2.2.1.3 Schéma en étoile Ventes

Le schéma en étoile du processus Ventes place la table `FACT_SALES_DWH` au centre, entourée des dimensions :

- DIM_PRODUCT
- DIM_CUSTOMER
- DIM_GEOGRAPHY
- DIM_DATE
- DIM_SHIPMODE

Chaque relation entre la table de faits et une dimension est de type *plusieurs-à-un* (* :1), conformément aux principes de modélisation dimensionnelle.

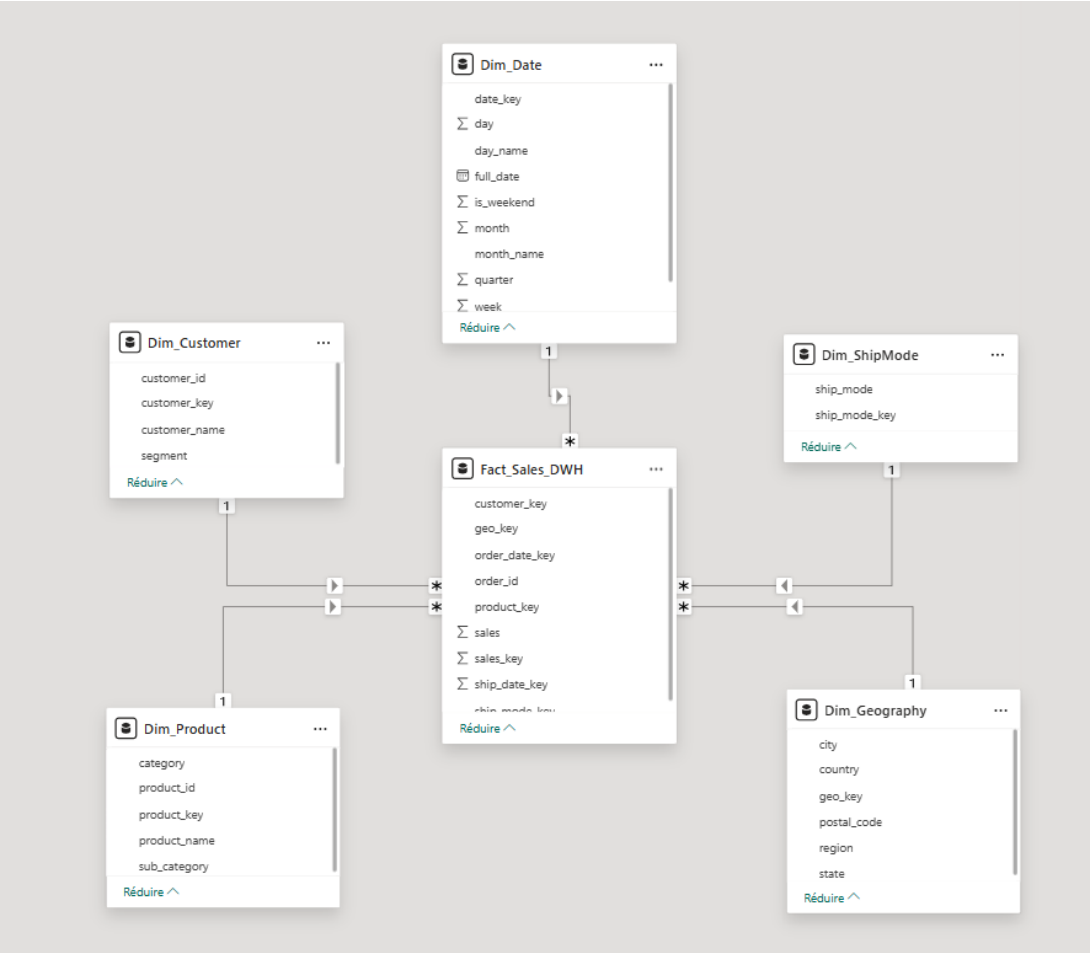


Figure 2.18 – Schéma en étoile du processus Ventes

2.2.1.4 Indicateurs de performance clés (KPI) Ventes

Les principaux indicateurs utilisés pour analyser les performances des ventes sont :

- **Chiffre d'affaires total** : Somme des ventes réalisées.
- **Profit total** : Somme des profits générés par les ventes.
- **Nombre total de commandes** : Nombre distinct d'identifiants de commande.
- **Panier moyen** : Montant moyen des ventes par commande.
- **Top 10 sous-catégories** : Classement des sous-catégories générant le plus de chiffre d'affaires.
- **Chiffre d'affaires par catégorie** : Répartition des ventes selon les catégories de produits.
- **Chiffre d'affaires par segment client** : Contribution des segments clients aux ventes.
- **Nombre de commandes par mois** : Volume mensuel d'activité commerciale.
- **Chiffre d'affaires mensuel** : Évolution temporelle des ventes.
- **Panier moyen par trimestre** : Évolution du comportement d'achat des clients selon les périodes.
- **Marge bénéficiaire** : Ratio entre profit total et chiffre d'affaires total.

2.2.2 Processus Clients

2.2.2.1 Table de faits Clients

La table de faits centrale du processus Clients est `FACT_CUSTOMER_PERF`. Elle capture la performance commerciale agrégée par client, par zone géographique et par période temporelle. Chaque ligne représente un enregistrement de performance pour un client donné à une date de commande donnée, dans une localisation donnée.

Table 2.7 – Structure de la table de faits `FACT_CUSTOMER_PERF`

Colonne	Type	Description
`perf_id`	INT (PK)	Clé surrogate de la table de faits
`customer_key`	INT (FK)	Référence vers `DIM_CUSTOMER`
`geography_key`	INT (FK)	Référence vers `DIM_GEOGRAPHY`
`order_date_key`	INT (FK)	Référence vers `DIM_DATE`
`total_sales`	FLOAT	Chiffre d'affaires total du client
`total_profit`	FLOAT	Bénéfice total généré par le client
`nb_orders`	INT	Nombre de commandes passées
`avg_basket`	FLOAT	Panier moyen par commande
`nb_categories`	INT	Nombre de catégories distinctes achetées

La granularité de cette table est définie au niveau *client – localisation – date de commande*. Les mesures stockées permettent de calculer les indicateurs clés de performance (KPIs) directement dans l'outil de visualisation.

2.2.2.2 Tables de dimensions Clients

Le processus Clients s'appuie sur trois tables de dimensions partagées, chacune représentant un axe d'analyse indépendant.

DIM_CUSTOMER La dimension client contient les attributs descriptifs de chaque client. La clé surrogate `customer_key` est générée par l'entrepôt de données afin de découpler les tables de la clé métier source `customer_id`, qui peut être sujette à modification dans le système d'information opérationnel.

Table 2.8 – Structure de la table de dimension `DIM_CUSTOMER`

Colonne	Type	Description
`customer_key`	INT (PK)	Clé surrogate générée par le DW
`customer_id`	VARCHAR	Identifiant métier source (ex. CG-12520)
`customer_name`	VARCHAR	Nom complet du client
`segment`	VARCHAR	Segment commercial : Consumer, Corporate, Home Office

DIM_GEOGRAPHY La dimension géographique modélise la localisation des clients selon une hiérarchie naturelle de cinq niveaux : *Pays* → *Région* → *État* → *Ville* → *Code postal*. La granularité est définie au niveau du code postal, qui constitue le niveau le plus fin disponible dans les données source. Cette hiérarchie permet le *drill-down* géographique dans Power BI, depuis la vue nationale jusqu'à la vue par quartier.

Table 2.9 – Structure de la table de dimension `DIM_GEOGRAPHY`

Colonne	Type	Description
`geography_key`	INT (PK)	Clé surrogate générée par le DW
`country`	VARCHAR	Pays
`region`	VARCHAR	Région (East, West, Central, South)
`state`	VARCHAR	État
`city`	VARCHAR	Ville
`postal_code`	VARCHAR	Code postal

DIM_DATE La dimension temporelle est construite en consolidant toutes les dates présentes dans les colonnes `Order Date` et `Ship Date` du fichier source. Elle joue le rôle d'une *dimension à rôles multiples* : la table de faits y fait référence deux fois via deux clés étrangères distinctes (`order_date_key` et `ship_date_key`), ce qui permet d'analyser les performances aussi bien selon la date de commande que selon la date d'expédition, en utilisant une seule et même table de dimension.

Table 2.10 – Structure de la table de dimension `DIM_DATE`

Colonne	Type	Description
`date_key`	INT (PK)	Clé surrogate générée par le DW
`full_date`	DATE	Date complète
`year`	INT	Année
`quarter`	INT	Trimestre (1 à 4)
`month`	INT	Mois (1 à 12)
`month_name`	VARCHAR	Nom du mois (January . . .December)
`week`	INT	Numéro de semaine dans l'année
`day_of_week`	VARCHAR	Jour de la semaine (Monday . . .Sunday)

2.2.2.3 Schéma en étoile Clients

Le schéma en étoile du processus Clients place la table de faits `FACT_CUSTOMER_PERF` au centre, entourée de ses trois dimensions. Les relations sont de type *plusieurs-à-un* ($*$:1) depuis la table de faits vers chaque dimension, conformément au modèle dimensionnel de Kimball.

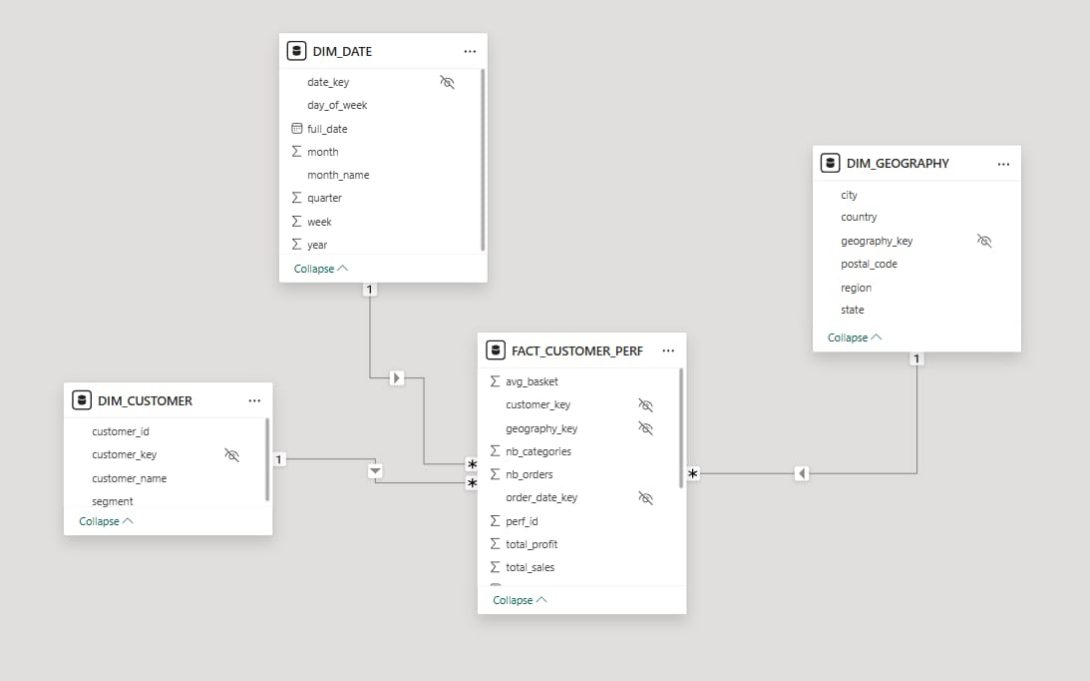


Figure 2.19 – Schéma en étoile du processus Clients

2.2.2.4 Indicateurs de performance clés (KPI)

Les principaux KPI pour le client sont :

- **Chiffre d'affaires total** : somme de `total_sales` par client.
- **Bénéfice total** : somme de `total_profit` par client.
- **Marge bénéficiaire** : ratio `total_profit` / `total_sales`, exprimé en pourcentage.
- **Valeur Vie Client (CLV)** : agrégation du chiffre d'affaires total d'un client sur l'ensemble de ses commandes, toutes périodes confondues.

- **Panier moyen** : valeur moyenne d'une commande par client.
- **Nombre de commandes** : volume d'activité total par client.
- **Diversité d'achats** : nombre de catégories de produits distinctes achetées, indicateur de l'étendue des besoins du client.

2.2.3 Processus Livraison

2.2.3.1 Table de faits Livraison

La table de faits pour le processus Livraison s'appelle **Fact_Mode_Ship_DWH**. Elle contient les mesures quantitatives relatives aux expéditions et permet de calculer les indicateurs de performance du processus logistique. Les principales clés et mesures de cette table sont :

- **customer_key** : clé primaire référant le client.
- **Date_key** : clé référant la date de la commande et de l'expédition.
- **Delivery_time** : durée de livraison en jours .
- **geography_key** : clé de la dimension géographique.
- **ship_mode_key** : clé de la dimension mode de livraison.
- **SHIPMENT ID** : identifiant unique de l'expédition.

2.2.3.2 Tables de dimensions Livraison

DIM_Geography

- city : ville du client
- country : pays du client
- geography_key : clé primaire de la dimension
- postal_code : code postal
- region : zone géographique
- state : état ou province

DIM_DATE

- Date_key : clé primaire de la dimension
- Order Date : date de la commande
- Ship Date : date d'expédition

DIM_ShipMode

- ship_mode : type de livraison (Standard, Express, etc.)
- ship_model_key : clé primaire de la dimension

DIM_Customer

- customer_id : identifiant du client
- customer_key : clé primaire de la dimension
- customer_name : nom du client
- Segment : type de client (Consumer, Corporate, Home Office)

2.2.3.3 Schéma en étoile Livraison

Le schéma en étoile du processus Livraison place la table de faits **Fact_Mode_Ship_DWH** au centre, avec les dimensions **DIM_Geography**, **DIM_DATE**, **DIM_ShipMode**, et **DIM_Customer** reliées autour par leurs clés primaires.

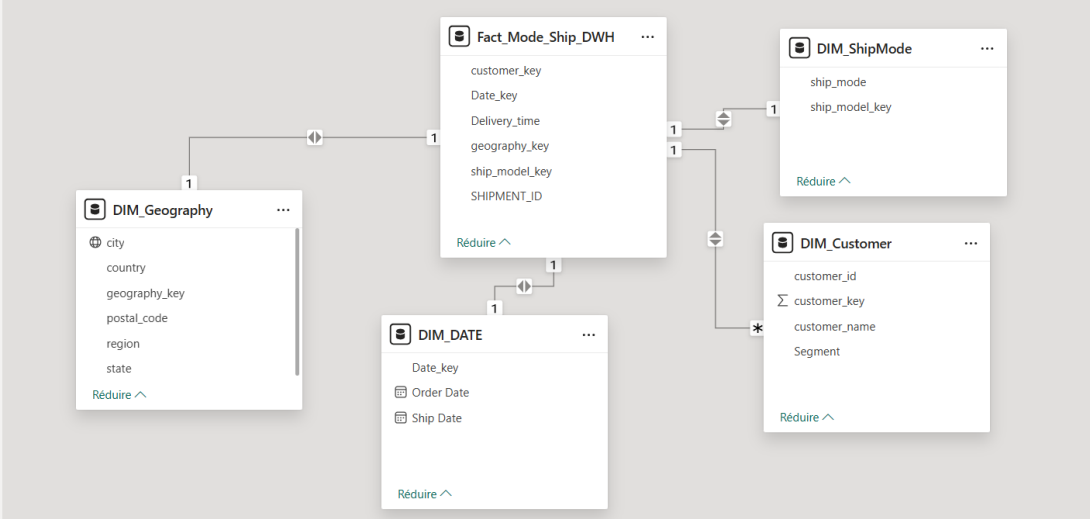


FIGURE 2.20 – Schéma en étoile du processus Livraison

2.2.3.4 Indicateurs de performance clés (KPI)

Les principaux KPI pour le processus Livraison incluent :

- **Délai moyen de livraison** : moyenne de la durée entre la commande et l'expédition.
- **Nombre d'expéditions par mode de livraison** : permet d'évaluer la répartition entre Standard, Express, etc.
- **Nombre d'expéditions par région** : analyse géographique de la performance logistique.
- **Performance client** : mesure de la fréquence et de la rapidité des livraisons par client ou segment.

Conclusion

Ce chapitre a présenté la modélisation multidimensionnelle du Data Warehouse, les tables de faits et de dimensions pour chaque processus clé, ainsi que les schémas en étoile associés. Il a également introduit les indicateurs de performance clés (KPI) pour les processus Ventes, Clients et Livraison, permettant de suivre et d'analyser les performances de l'entreprise. Cette structure servira de base pour les analyses futures et pour l'exploitation des données dans le système décisionnel.

Chapitre 3

Outils et Visualisation

Introduction

Ce chapitre présente les outils utilisés pour la mise en place du système décisionnel et décrit la création et l'analyse des dashboards interactifs. L'objectif est de fournir des visualisations claires pour chaque processus métier afin de faciliter l'interprétation des données et la prise de décision.

3.1 Outils utilisés

Pour la réalisation de ce projet décisionnel, un ensemble d'outils et de technologies a été sélectionné afin de couvrir les différentes phases du projet, notamment le processus ETL, la modélisation des données, l'analyse décisionnelle et l'intégration d'une composante d'intelligence artificielle. Cet environnement a permis de concevoir un système complet, allant du traitement des données brutes jusqu'à leur visualisation interactive et leur exploitation à des fins analytiques et prédictives.

3.1.1 Python

Python est un langage de programmation open-source largement utilisé dans le domaine de la data science et de l'analyse de données. Dans ce projet, Python a été utilisé principalement pour la mise en place du processus ETL ainsi que pour l'intégration de la composante d'intelligence artificielle.



Figure 3.1 – Logo de Python

3.1.2 Power BI

Power BI est un outil de Business Intelligence développé par Microsoft, permettant de créer des tableaux de bord interactifs et des visualisations dynamiques à partir de données

structurées. Dans ce projet, Power BI a été utilisé principalement pour l'analyse des données et la création de dashboards interactifs facilitant la visualisation des indicateurs de performance (KPI) et la prise de décision.



Figure 3.2 – Logo de Power BI

3.2 Création et analyse des dashboards Power BI

3.2.1 Dashboard processus Ventes

Le dashboard dédié au processus Ventes permet d'analyser les performances commerciales à travers différents axes analytiques tels que les produits, les catégories et l'évolution temporelle des ventes.

Ce dashboard est structuré en trois pages complémentaires, permettant une exploration progressive des indicateurs clés. Les visualisations reposent principalement sur la table de faits `FACT_SALES_DWH` ainsi que sur les dimensions `DIM_PRODUCT`, `DIM_DATE` et `DIM_CUSTOMER`.

Les principaux indicateurs clés affichés dans ce dashboard sont :

- **Chiffre d'affaires total** : Somme des ventes réalisées.
- **Profit total** : Somme des profits générés par les ventes.
- **Nombre total de commandes** : Nombre distinct d'identifiants de commande.
- **Panier moyen** : Montant moyen des ventes par commande.
- **Top sous-catégories** : Classement des sous-catégories générant le plus de chiffre d'affaires.
- **Chiffre d'affaires par catégorie** : Répartition des ventes selon les catégories de produits.
- **Chiffre d'affaires par segment client** : Contribution des segments clients aux ventes.
- **Nombre de commandes par mois** : Volume mensuel d'activité commerciale.
- **Chiffre d'affaires mensuel** : Évolution temporelle des ventes.
- **Panier moyen par trimestre** : Évolution du comportement d'achat des clients selon les périodes.
- **Marge bénéficiaire** : Ratio entre profit total et chiffre d'affaires total.

Des filtres interactifs permettent d'analyser les données selon :

- L'année
- La catégorie de produits
- La sous-catégorie

Ces filtres offrent une navigation dynamique et facilitent l'analyse multidimensionnelle des performances commerciales.

3.2.1.1 Dashboard 1 — Performances des produits et catégories

La première page du dashboard est consacrée à l'analyse des performances commerciales par catégorie et sous-catégorie de produits.

Elle permet d'identifier les produits les plus vendus ainsi que les catégories générant le plus de chiffre d'affaires.

Cette page contient plusieurs visualisations clés :

- **Top sous-catégories — Barres horizontales**
  Ce graphique présente les sous-catégories générant le plus de chiffre d'affaires.
  - Axe Y : `Dim_Product[sub_category]`
  - Valeur : `[CA Total]`
  - Tri : décroissant

  Ce visuel permet d'identifier rapidement les sous-catégories les plus rentables.
- **Chiffre d'affaires par catégorie et segment — Barres groupées**
  Ce graphique compare le chiffre d'affaires généré par chaque segment client pour différentes catégories de produits.
  - Axe Y : `segment`
  - Légende : `category`
  - Valeur : `[CA Total]`

  Il permet d'analyser la contribution des segments clients aux ventes des différentes catégories.
- **Matrice détaillée des ventes**
  La matrice permet d'afficher les performances commerciales détaillées par catégorie et sous-catégorie.
  - Lignes : `category → sub_category`
  - Valeurs :
    - `[CA Total]`
    - `[Profit Total]`
    - `[Marge Pct]`

  Ce tableau fournit une vue détaillée facilitant l'analyse comparative des performances.

Des cartes KPI sont également affichées dans cette page :

- Chiffre d'affaires total
- Profit total
- Nombre total de commandes
- Panier moyen

Ces indicateurs permettent une lecture rapide de la performance commerciale globale.

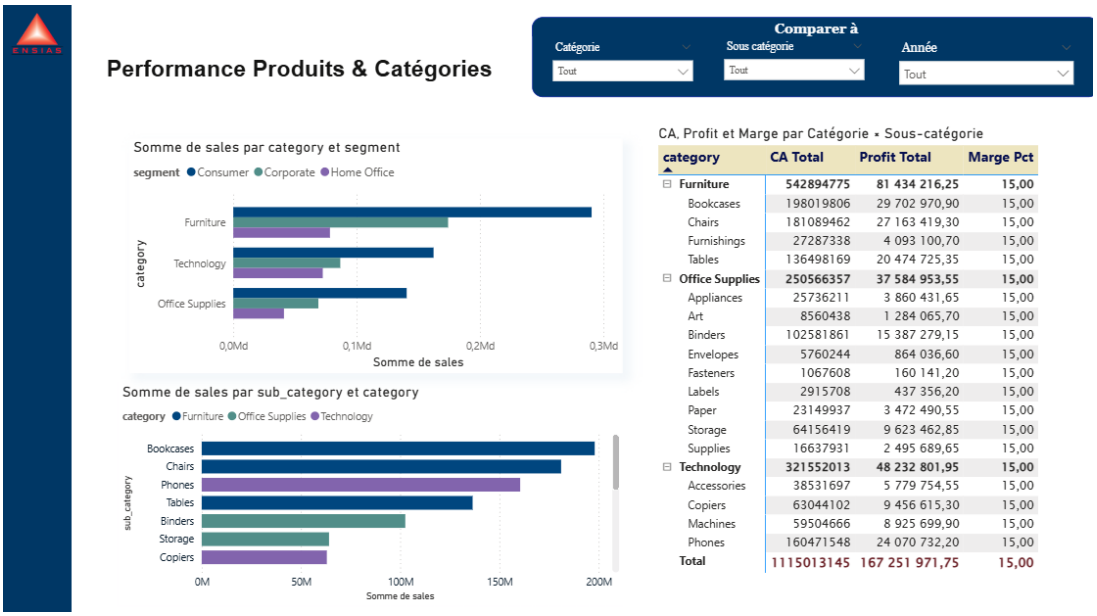


FIGURE 3.3 – Dashboard 1 — Performances des produits et catégories

3.2.1.2 Dashboard 2 — Tendances mensuelles des ventes

La deuxième page analyse l'évolution des ventes dans le temps, en se basant sur la dimension temporelle `DIM_DATE`.

Elle permet d'observer les variations mensuelles des ventes et du nombre de commandes.

Les visualisations principales sont :

- **Chiffre d'affaires et nombre de commandes par mois — Courbe double axe**

  Ce graphique représente simultanément l'évolution mensuelle du chiffre d'affaires et du nombre de commandes.

  - Axe X : `month_name`
  - Axe Y1 : `[CA Total]`
  - Axe Y2 : `[Nb Commandes]`

  Il permet d'identifier les périodes de forte activité commerciale.

- **Nombre de commandes par mois et segment — Histogramme empilé**

  Ce graphique montre la répartition mensuelle des commandes selon les segments clients.

  - Axe X : `month_name`
  - Légende : `segment`
  - Valeur : `[Nb Commandes]`

  Il permet d'analyser le comportement des différents segments clients au fil du temps.

Cette page inclut également les cartes KPI suivantes :

- Chiffre d'affaires total
- Profit total

- Nombre total de commandes
- Panier moyen

Ces indicateurs fournissent une vision synthétique de la performance mensuelle.

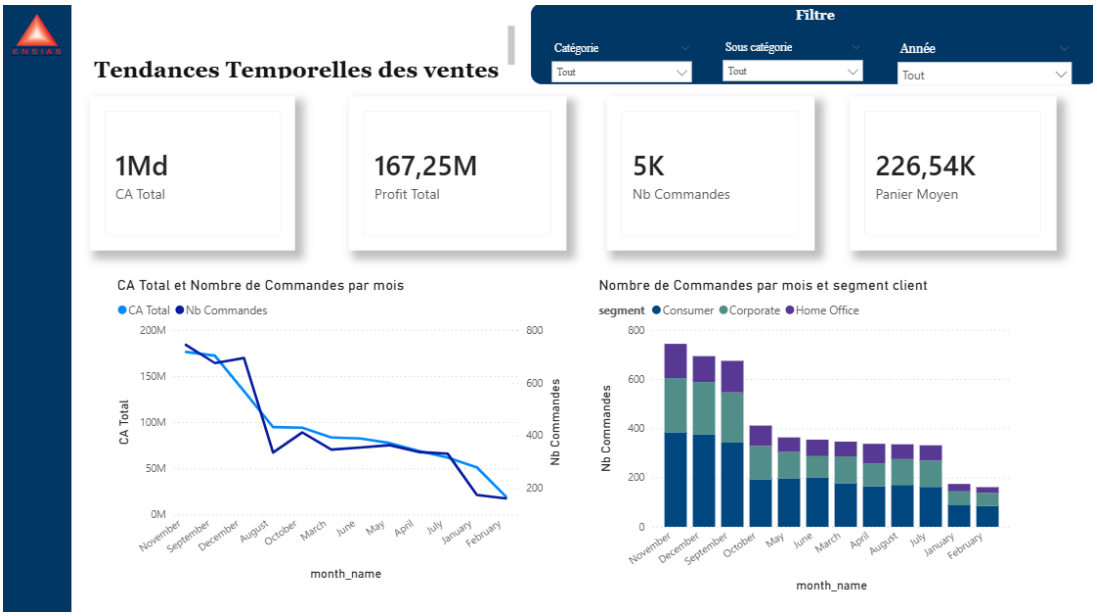


FIGURE 3.4 – Dashboard 2 — Tendances mensuelles des ventes

3.2.1.3 Dashboard 3 — Tendances trimestrielles et panier moyen

La troisième page permet d'analyser les tendances trimestrielles des ventes ainsi que l'évolution du panier moyen.

Elle repose sur l'utilisation de la hiérarchie temporelle fournie par la dimension `DIM_DATE`.

Les visualisations principales sont :

- **Somme des ventes par mois**

  Ce graphique montre l'évolution globale du chiffre d'affaires mensuel.

  - Axe X : mois
  - Valeur : `[CA Total]`

  Il permet d'identifier les tendances saisonnières.

- **Panier moyen par trimestre — Courbes multi-séries**

  Ce graphique présente l'évolution du panier moyen par catégorie de produits.

  - Axe X : `quarter`
  - Légende : `category`
  - Valeur : `[Panier Moyen]`

  Ce visuel permet d'identifier les catégories ayant le panier moyen le plus élevé.

Cette page comprend également les cartes KPI globales.

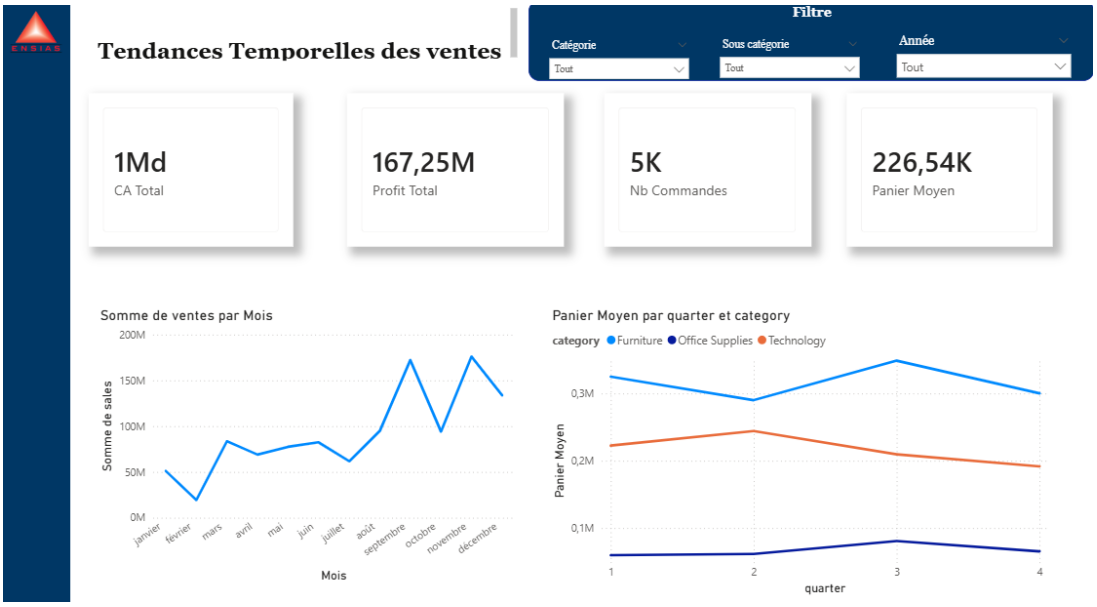


FIGURE 3.5 – Dashboard 3 — Tendances trimestrielles des ventes

3.2.2 Dashboard processus Clients

3.2.2.1 Dashboard 1 — Vue générale clients

Le premier tableau de bord, intitulé Customer Overview, constitue la page d'entrée du rapport Power BI dédié à l'analyse clients. Il présente en en-tête quatre indicateurs clés de performance sous forme de cartes synthétiques : le chiffre d'affaires total, le bénéfice total, le nombre de clients distincts et la valeur vie client moyenne (CLV). Ces métriques offrent une lecture immédiate de la santé commerciale de l'entreprise. La page intègre également un graphique en anneau illustrant la répartition du chiffre d'affaires par segment client (Consumer, Corporate, Home Office), un graphique en barres horizontales classant les dix meilleurs clients selon leur CLV, ainsi qu'un histogramme comparant le volume de commandes par segment. Un segment visuel interactif permet de filtrer l'ensemble des visuels par segment en un seul clic, rendant l'exploration des données intuitive et rapide.

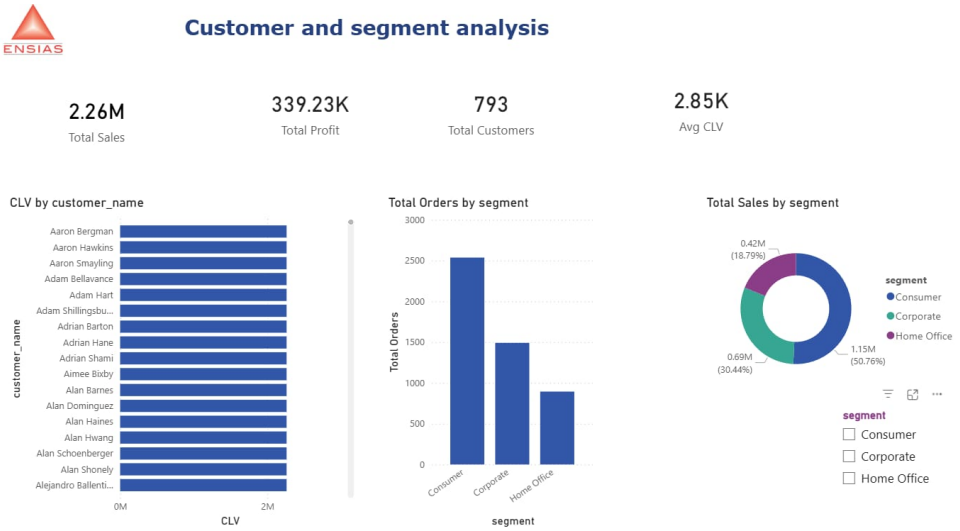


FIGURE 3.6 – Dashboard processus Clients

3.2.2.2 Dashboard 2 — Géographie clients

Le deuxième tableau de bord, intitulé Customer Geography, est consacré à l'analyse spatiale du portefeuille clients. Il exploite la hiérarchie géographique définie dans la dimension DIM_GEOGRAPHY— pays, région, état, ville, code postal — pour permettre une navigation par drill-down depuis la vue nationale jusqu'au niveau de la ville. La page s'articule autour d'un visuel cartographique représentant le chiffre d'affaires par état sous forme de bulles proportionnelles, accompagné d'un graphique en barres comparant les performances par région. Un tableau détaillé liste les villes avec leur chiffre d'affaires, leur bénéfice et leur taux de marge, permettant d'identifier les zones géographiques les plus rentables et celles nécessitant une attention particulière. Un graphique additionnel présente la CLV moyenne par région, révélant les disparités de valeur client selon la localisation. Deux segments interactifs — région et segment client — permettent de croiser les analyses géographiques et comportementales simultanément.

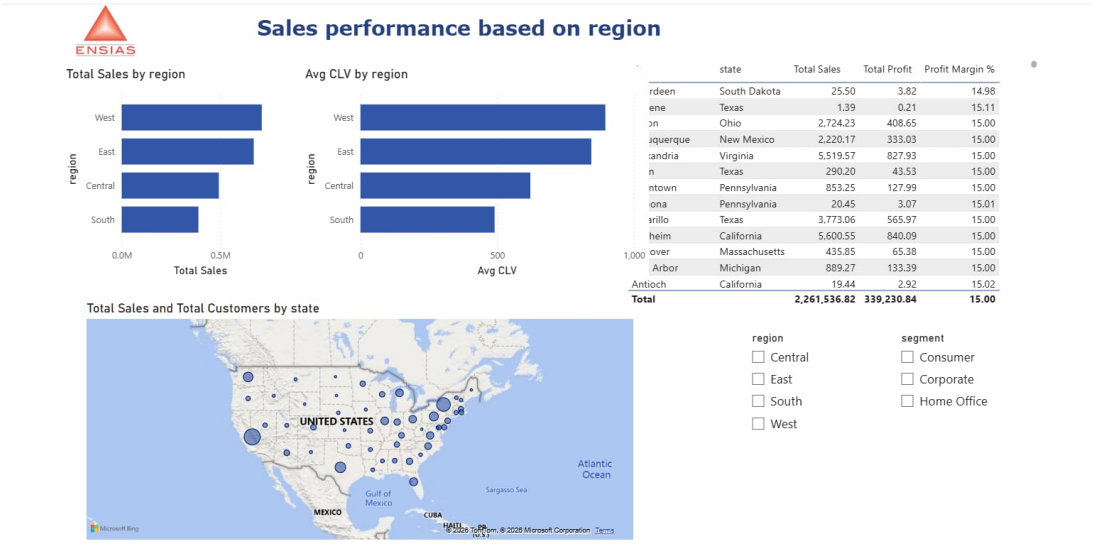


Figure 3.7 – Dashboard 2 — Géographie clients

3.2.2.3 Dashboard 3 — Tendances clients

Le troisième tableau de bord, intitulé Customer Trends, est dédié à l'analyse temporelle de l'activité clients. Il exploite la dimension DIM_DATE pour suivre l'évolution des indicateurs dans le temps et détecter les tendances, saisonnalités et ruptures de comportement. Un premier graphique en courbes superpose l'évolution mensuelle du chiffre d'affaires et du nombre de commandes sur un double axe, permettant d'identifier les périodes de forte activité. Un second graphique suit la progression de la CLV moyenne par trimestre, ventilée par segment, afin d'évaluer si la valeur des clients augmente ou se dégrade dans le temps. Un histogramme empilé mensuel décompose le volume de commandes par segment, révélant les dynamiques de croissance propres à chaque catégorie de clients. Enfin, une courbe du panier moyen mensuel complète l'analyse en mesurant l'évolution du comportement d'achat individuel. Un segment de type plage temporelle sur l'année permet de restreindre l'ensemble des visuels à une période spécifique.

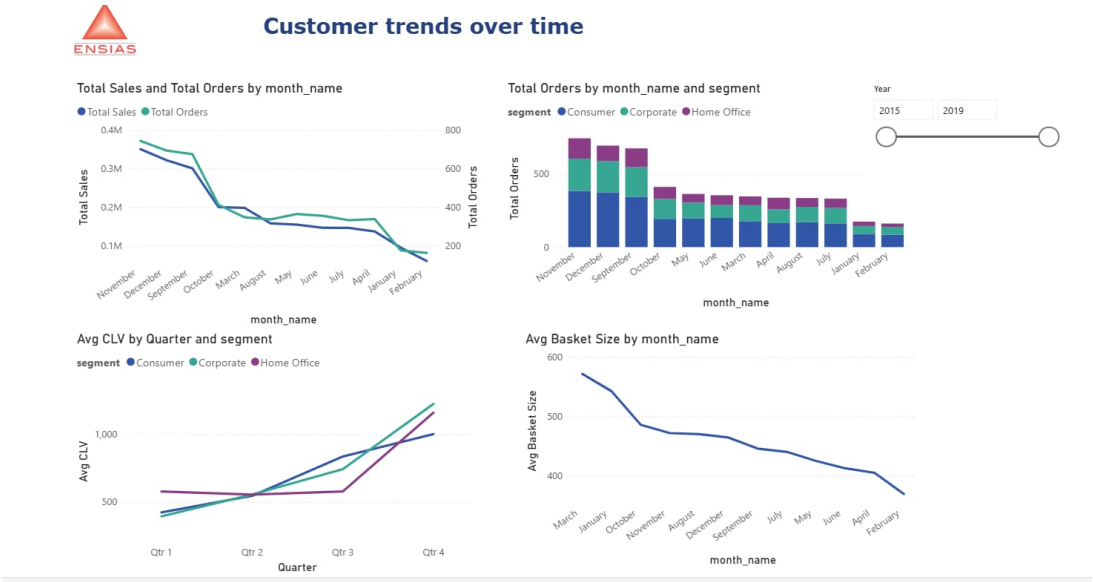


Figure 3.8 – Dashboard 3 — Tendances clients

3.2.3 Dashboard processus Livraison

Le dashboard dédié au processus de livraison a pour objectif principal de fournir une vision globale et détaillée de la performance logistique de l'entreprise. Il permet de suivre les indicateurs clés liés aux délais de livraison, aux modes d'expédition ainsi qu'au comportement des clients en matière de choix de livraison.

Ce tableau de bord interactif facilite l'analyse des données et aide les décideurs à identifier les points d'amélioration afin d'optimiser les opérations logistiques et améliorer la satisfaction client.

Objectifs du dashboard

Les principaux objectifs de ce dashboard sont :

- Suivre le volume total des commandes livrées.
- Analyser les délais moyens de livraison.
- Étudier la répartition des commandes selon les modes de livraison.
- Comprendre les préférences des clients en fonction de leur segment.
- Identifier les tendances mensuelles des délais de livraison.

Filtres et interactivité

Le dashboard intègre des filtres dynamiques permettant d'affiner l'analyse :

- **Ville** : analyser les performances par zone géographique.
- **Année** : observer l'évolution dans le temps.
- **État** : comparer les performances entre différentes régions.

Ces filtres offrent une exploration flexible et personnalisée des données.

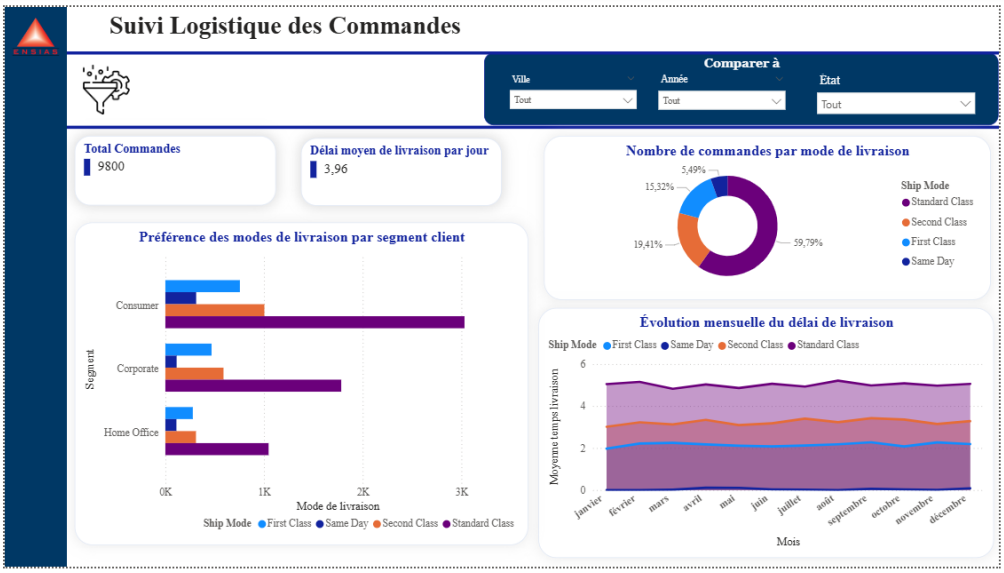


FIGURE 3.9 – Dashboard du processus Livraison

Conclusion

Ce chapitre a présenté les outils utilisés pour l'exploitation du Data Warehouse et la création des dashboards interactifs. Chaque processus métier (Ventes, Clients, Livraison) peut disposer de plusieurs dashboards Power BI, permettant une visualisation claire et synthétique des KPIs. Ces visualisations constituent un support essentiel à la prise de décision et à l'amélioration des performances de l'entreprise.

Chapitre 4

Intégration d'une Composante IA

Introduction

Ce chapitre présente l'intégration d'une composante d'intelligence artificielle dans le système décisionnel. Il détaille deux approches principales : la prévision du chiffre d'affaires à l'aide d'un modèle de régression, et la segmentation des clients via l'algorithme K-Means. Ces techniques permettent d'exploiter les données de manière avancée afin d'améliorer l'analyse et la prise de décision stratégique.

4.1 Prévision des ventes (CA sur 3 mois)

Dans le cadre de ce projet, une composante d'intelligence artificielle a été intégrée afin d'apporter une valeur ajoutée au tableau de bord interactif. Cette partie consiste à développer un modèle simple permettant de prédire l'évolution du chiffre d'affaires (CA) sur les trois prochains mois à partir des données historiques disponibles dans le dataset *Sample Superstore*.

L'objectif principal de cette analyse prédictive est d'aider l'entreprise à anticiper les tendances futures et à améliorer la prise de décision stratégique.

4.1.1 Analyse exploratoire des données

Avant la modélisation, une analyse statistique descriptive a été réalisée afin de mieux comprendre la distribution des variables.

Listing 4.1 – Statistiques descriptives

```
1 print(df.describe())
```

```
Statistiques descriptives :
            Row ID                     Order Date   Postal Code         Sales  \
count  9994.000000                           9994   9994.000000   9994.000000
mean   4997.500000  2016-04-30 00:07:12.259355648  55190.379428    229.858001
min       1.000000            2014-01-03 00:00:00   1040.000000      0.444000
25%    2499.250000            2015-05-23 00:00:00  23223.000000     17.280000
50%    4997.500000            2016-06-26 00:00:00  56430.500000     54.490000
75%    7495.750000            2017-05-14 00:00:00  90008.000000    209.940000
max    9994.000000            2017-12-30 00:00:00  99301.000000  22638.480000
std    2885.163629                            NaN  32063.693350    623.245101

          Quantity     Discount       Profit
count  9994.000000  9994.000000  9994.000000
mean      3.789574     0.156203    28.656896
min       1.000000     0.000000 -6599.978000
25%       2.000000     0.000000     1.728750
50%       3.000000     0.200000     8.666500
75%       5.000000     0.200000    29.364000
max      14.000000     0.800000  8399.976000
std       2.225110     0.206452   234.260108
```

FIGURE 4.1 – Statistiques descriptives du dataset

Ces statistiques montrent que :

- Les ventes présentent une forte dispersion (écart-type élevé)
- Certaines valeurs extrêmes sont présentes (max élevé)
- Les profits peuvent être négatifs, indiquant des pertes sur certaines transactions

4.1.2 Analyse de la tendance

Une régression linéaire a été utilisée pour vérifier la tendance globale.

Listing 4.2 – Régression linéaire

```
1 lr = LinearRegression()
2 lr.fit(X_lin, y_lin)
3 y_lin_pred = lr.predict(X_lin)
```

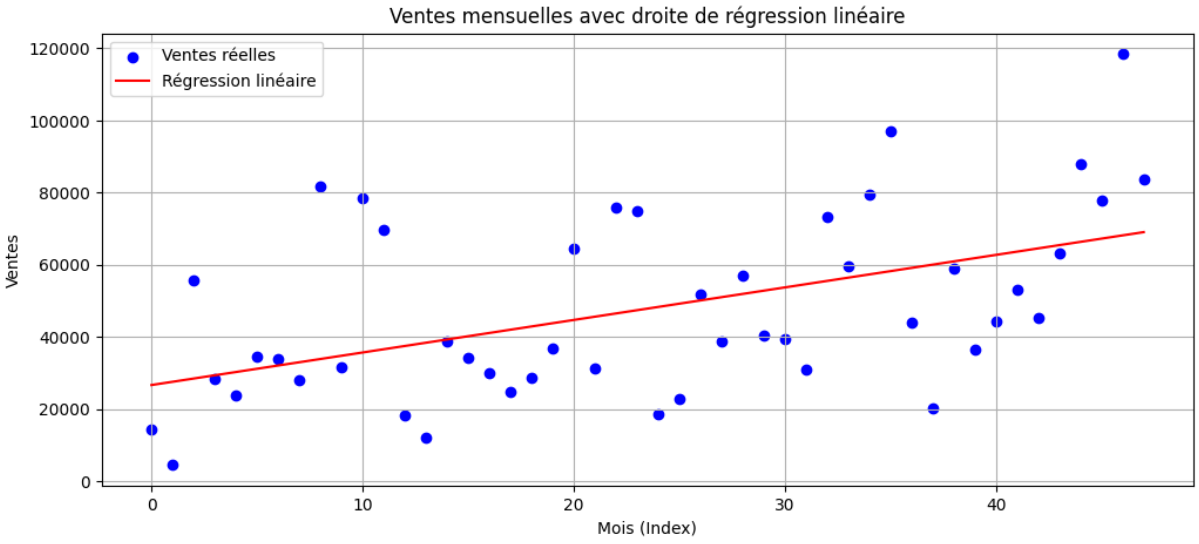


FIGURE 4.2 – Tendance des ventes avec régression linéaire

La droite de régression linéaire met en évidence une tendance globale croissante du chiffre d'affaires au fil du temps. Cela indique que, sur l'ensemble de la période étudiée, les ventes augmentent en moyenne.

Cependant, la dispersion importante des points autour de la droite de régression montre que le modèle linéaire simple ne parvient pas à capturer les fluctuations mensuelles et les effets saisonniers observés dans les données. De plus, ce modèle ne prend pas en compte les dépendances temporelles entre les ventes successives.

Ces limites justifient l'utilisation d'un modèle plus avancé intégrant des variables temporelles et un mécanisme de régularisation, tel que la régression Ridge, afin d'améliorer la précision des prévisions.

4.1.3 Création des variables explicatives (Feature Engineering)

Afin de dépasser les limites du modèle linéaire simple et d'améliorer la performance prédictive, plusieurs variables temporelles ont été créées. Ces variables permettent de capturer la tendance, la saisonnalité ainsi que la dépendance temporelle des ventes.

Table 4.1 – Variables explicatives utilisées

Feature	Description
Month	Mois de l'année
MonthIndex	Index temporel représentant la tendance globale
Lag1	Chiffre d'affaires du mois précédent
Lag12	Chiffre d'affaires du même mois de l'année précédente
Rolling3	Moyenne des ventes sur 3 mois
SalesDiff	Variation mensuelle des ventes

Ces variables enrichissent le modèle en intégrant des informations temporelles essentielles, permettant ainsi une meilleure représentation de la dynamique réelle du chiffre d'affaires et une amélioration de la qualité des prévisions.

Listing 4.3 – Création des features

```
data['Month']       = data.index.month
data['MonthIndex'] = np.arange(len(data))
data['Lag1']       = data['Sales'].shift(1)
data['Lag12']      = data['Sales'].shift(12)
data['Rolling3']   = data['Sales'].rolling(window=3).mean()
data['SalesDiff'] = data['Sales'].diff(1)
```

4.1.3.1 Division des données

Les données ont été séparées en :

- 80% pour l'entraînement
- 20% pour le test

Listing 4.4 – Split train/test

```
split = int(len(X_scaled)*0.8)
X_train, X_test = X_scaled[:split], X_scaled[split:]
y_train, y_test = y[:split], y[split:]
```

4.1.4 Modélisation avec Ridge Regression

Le modèle retenu pour la prévision du chiffre d'affaires est une **régression Ridge**. Ce choix est motivé par la présence de plusieurs variables explicatives fortement liées entre elles, notamment les ventes passées utilisées comme variables de retard (*lag*), ce qui peut entraîner un risque de sur-apprentissage dans une régression linéaire classique.

La régression Ridge introduit une régularisation de type L2, qui limite l'amplitude des coefficients du modèle et améliore sa capacité de généralisation, tout en conservant une relation linéaire entre les variables explicatives et la variable cible.

La fonction de coût de la régression Ridge est donnée par :

$$J(\beta) = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^{p} \beta_j^2 \tag{4.1}$$

où :

- y_i : valeur réelle
- $\hat{y}_i$: valeur prédite
- β_j : coefficients du modèle
- λ : paramètre de régularisation (contrôle la pénalisation)

Le terme de pénalisation $\lambda \sum \beta_j^2$ permet de réduire la complexité du modèle en évitant que certains coefficients ne prennent des valeurs trop élevées, ce qui limite le sur-apprentissage et améliore la robustesse du modèle face aux nouvelles données.

Listing 4.5 – Modèle Ridge

```
model = Ridge(alpha=1.0)
model.fit(X_train, y_train)
```

4.1.5 Évaluation du modèle

Les performances du modèle Ridge ont été évaluées sur le jeu de test à l'aide de plusieurs métriques afin de mesurer la qualité des prédictions.

Table 4.2 – Métriques de performance du modèle Ridge sur le jeu de test

Métrique	**Valeur**	**Interprétation**
MSE	16 623 585,10	Pénalise fortement les grandes erreurs
MAE	3 318,56 $	Erreur moyenne de prédiction mensuelle
R^2	**0,9705**	97,05% de la variance expliquée

Un coefficient de détermination $R^2 = 0{,}9705$ indique que le modèle explique une grande partie de la variabilité du chiffre d'affaires, ce qui traduit une excellente capacité prédictive sur les données de test.

4.1.5.1 Visualisation des prédictions

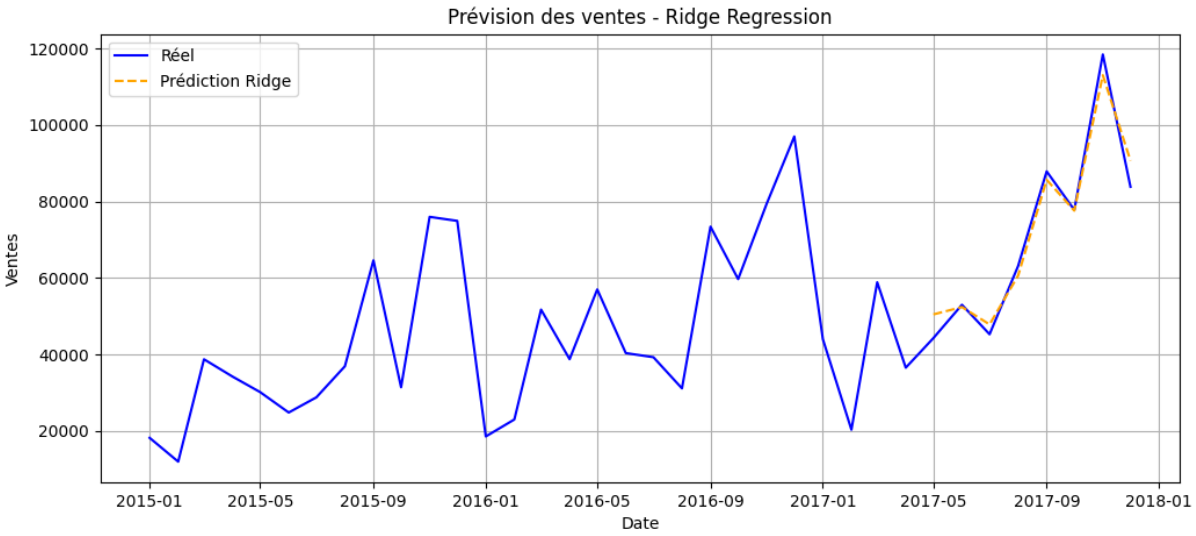


FIGURE 4.3 – Comparaison des ventes réelles et prédites (Ridge)

L'analyse de la Figure montre que les prédictions du modèle Ridge suivent de manière très proche l'évolution des ventes réelles. La courbe prédite reproduit correctement la tendance globale ainsi que la majorité des variations observées dans la série temporelle.

On constate que les écarts entre les valeurs réelles et prédites restent faibles, ce qui confirme la bonne capacité du modèle à généraliser sur des données non vues. Les légères différences observées lors de certains pics peuvent s'expliquer par la variabilité importante des ventes et par des facteurs non capturés par le modèle.

Globalement, ces résultats confirment la pertinence de la régression Ridge pour la prévision du chiffre d'affaires et sa capacité à fournir des estimations fiables pour l'aide à la décision.

4.1.6 Prévision des 3 prochains mois

Le modèle a été utilisé pour générer des prévisions futures :

Listing 4.6 – Prévision future

```
1 future_pred = model.predict(future_X)
```

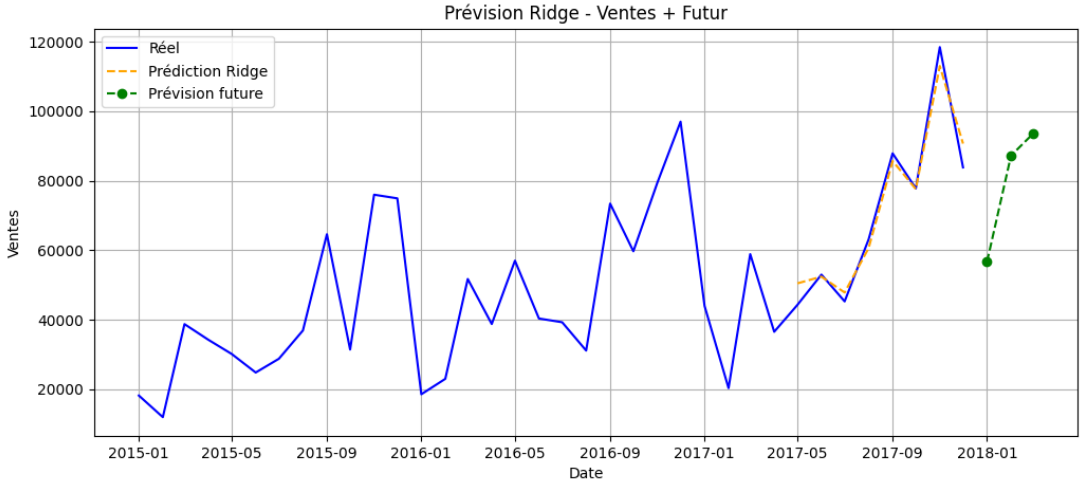


FIGURE 4.4 – Prévision des ventes sur les 3 prochains mois

La Figure montre les prévisions du chiffre d'affaires pour les trois prochains mois générées par le modèle Ridge. .

Les valeurs prédites restent cohérentes avec les niveaux observés dans les périodes précédentes, ce qui indique que le modèle a bien capturé la dynamique globale de la série temporelle. Cette évolution suggère une amélioration potentielle de la performance commerciale à court terme.

Ces prévisions constituent un outil d'aide à la décision, permettant aux responsables de mieux anticiper les tendances futures et d'ajuster leurs stratégies commerciales en conséquence.

4.2 Segmentation des clients par clustering K-Means

Dans cette partie, une approche de segmentation client a été mise en place afin de regrouper automatiquement les clients selon leur comportement d'achat. Cette segmentation permet d'identifier différents profils de clients et d'adapter les stratégies marketing et commerciales en conséquence.

4.2.1 Agrégation des données par client

Afin de réaliser la segmentation, les données ont été agrégées au niveau du client. Pour chaque client, trois indicateurs principaux ont été calculés :

- Le chiffre d'affaires total (**TotalSales**)
- Le profit total (**TotalProfit**)
- La quantité totale achetée (**TotalQuantity**)

Listing 4.7 – Agrégation des données par client

```
customer_data = df.groupby('Customer ID').agg({
    'Sales': 'sum',
    'Profit': 'sum',
    'Quantity': 'sum'
}).reset_index()
```

```
6
7 customer_data.columns = ['CustomerID', 'TotalSales', 'TotalProfit',
      'TotalQuantity']
```

Cette transformation permet d'obtenir une vision globale du comportement de chaque client, ce qui facilite la segmentation.

4.2.2 Vérification des valeurs aberrantes

Avant d'appliquer l'algorithme de clustering, il est important d'analyser la présence de valeurs aberrantes pouvant influencer les résultats du modèle.

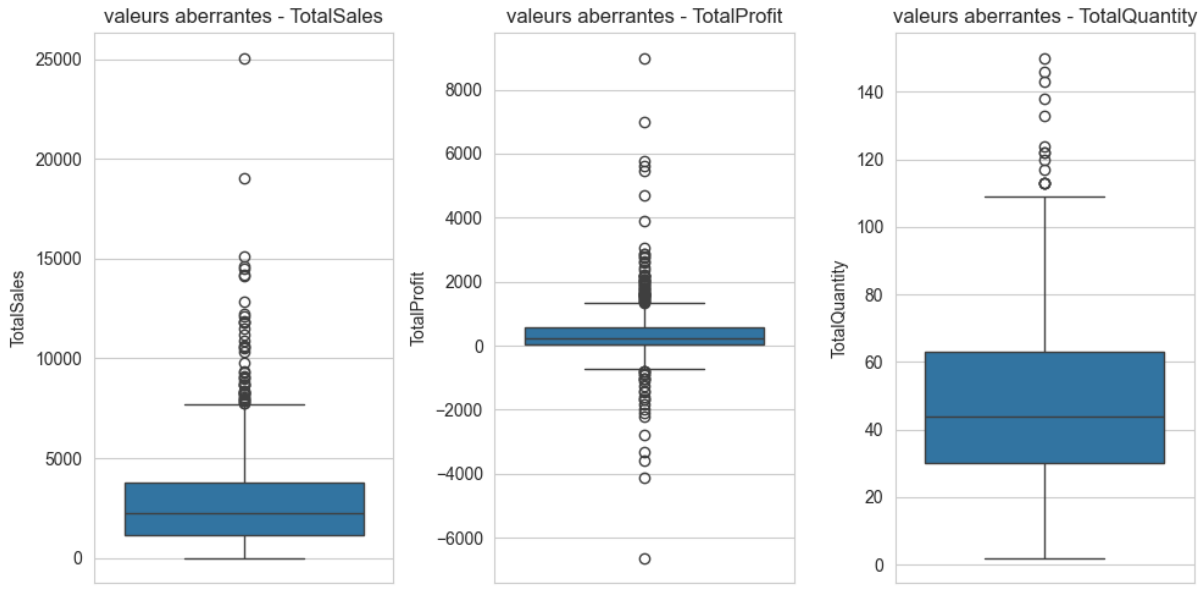


Figure 4.5 – Détection des valeurs aberrantes pour TotalSales, TotalProfit et TotalQuantity

L'analyse des boxplots met en évidence la présence de nombreuses valeurs aberrantes dans les trois variables étudiées :

- **TotalSales** : présence de clients avec un chiffre d'affaires très élevé, nettement supérieur à la majorité, indiquant des clients à forte contribution.
- **TotalProfit** : existence de valeurs extrêmes positives mais également négatives, ce qui signifie que certains clients génèrent des pertes importantes.
- **TotalQuantity** : dispersion notable avec quelques clients ayant des volumes d'achat très élevés par rapport à la moyenne.

Ces valeurs aberrantes peuvent biaiser les résultats du clustering, car l'algorithme K-Means est sensible aux échelles et aux valeurs extrêmes.

4.2.3 Normalisation des données

Les variables utilisées pour le clustering présentent des échelles différentes et contiennent des valeurs aberrantes. Afin de garantir des résultats fiables, une normalisation robuste a été appliquée à l'aide de **RobustScaler**.

Contrairement à la normalisation standard, cette méthode est moins sensible aux valeurs extrêmes car elle utilise la médiane et l'intervalle interquartile.

La transformation appliquée est définie par la formule suivante :

$$X_{scaled} = \frac{X - \text{médiane}(X)}{IQR(X)} \tag{4.2}$$

où :

- médiane(X) : la valeur médiane de la variable
- $IQR(X) = Q3 - Q1$: l'intervalle interquartile (différence entre le troisième et le premier quartile)

Cette transformation permet de centrer les données autour de zéro tout en réduisant l'influence des valeurs aberrantes, ce qui améliore la qualité du clustering.

Listing 4.8 – Normalisation avec RobustScaler

```
scaler = RobustScaler()
X = scaler.fit_transform(customer_data[['TotalSales', 'TotalProfit'
    , 'TotalQuantity']])
```

Cette étape permet d'harmoniser les variables et d'éviter qu'une variable dominante n'influence excessivement la formation des clusters.

4.2.4 Détermination du nombre optimal de clusters

La méthode du coude (*Elbow Method*) a été utilisée afin de déterminer le nombre optimal de clusters. Cette méthode consiste à analyser la variation de l'inertie (WCSS : Within-Cluster Sum of Squares) en fonction du nombre de clusters.

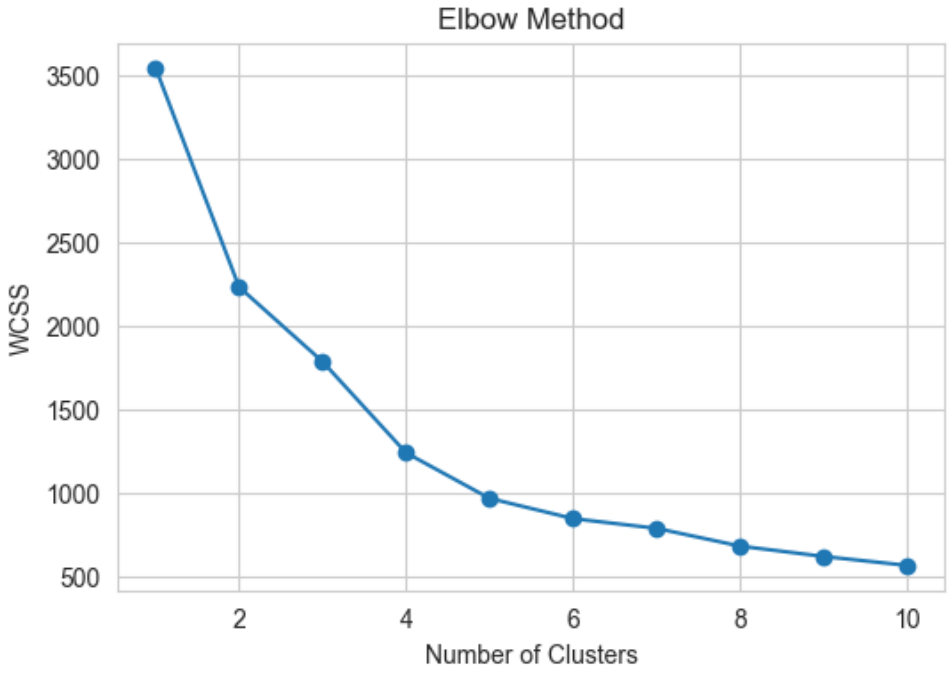


Figure 4.6 – Méthode du coude pour déterminer le nombre optimal de clusters

L'analyse de la courbe montre une diminution importante de l'inertie jusqu'à $k = 3$, après quoi la réduction devient plus progressive. Ce point de rupture représente le "coude" de la courbe.

Ainsi, le choix de $k = 3$ **clusters** est retenu comme un compromis optimal entre la qualité de la segmentation et la simplicité du modèle.

4.2.5 Application de l'algorithme K-Means

L'algorithme **K-Means** a été appliqué avec $k = 3$ afin de segmenter les clients.

K-Means est un algorithme de clustering non supervisé qui vise à regrouper les observations en k groupes en minimisant la distance entre les points d'un même cluster et leur centre (appelé centroïde).

Le principe de fonctionnement est le suivant :

- Initialisation aléatoire de k centroïdes
- Affectation de chaque client au cluster le plus proche
- Recalcul des centroïdes comme moyenne des points du cluster
- Répétition jusqu'à convergence

L'objectif de K-Means est de minimiser la somme des distances intra-cluster :

$$J = \sum_{k=1}^{K} \sum_{i \in C_k} ||x_i - \mu_k||^2 \tag{4.3}$$

où :

- x_i : un client
- μ_k : le centroïde du cluster k
- C_k : l'ensemble des points du cluster k

Listing 4.9 – Modèle K-Means

```
kmeans = KMeans(n_clusters=3, random_state=42)
customer_data['Cluster'] = kmeans.fit_predict(X)
```

Chaque client est ainsi assigné à un cluster en fonction de ses caractéristiques (ventes, profit, quantité), ce qui permet de regrouper les clients ayant des comportements similaires.

4.2.6 Analyse des clusters

Afin de mieux comprendre les profils de clients, la moyenne des variables a été calculée pour chaque cluster.

Listing 4.10 – Analyse des clusters

```
cluster_summary = customer_data.groupby('Cluster')[['TotalSales','
    TotalProfit','TotalQuantity']].mean()
```

Cluster	TotalSales	TotalProfit	TotalQuantity
0	6452.890908	-1903.413871	60.375000
1	7194.412135	1765.990716	69.372727
2	2049.994148	209.135016	43.691958

Figure 4.7 – Moyennes des indicateurs par cluster

Ces résultats montrent des comportements clients distincts selon les clusters, notamment en termes de rentabilité et de volume d'achat.

4.2.7 Interprétation métier des segments

Afin de faciliter l'analyse et l'exploitation des résultats, des noms métier ont été attribués à chaque cluster :

- **Cluster 0 – Clients non rentables** : ces clients génèrent un chiffre d'affaires relativement élevé mais avec un profit négatif. Cela peut être dû à des remises importantes ou à des coûts élevés.
- **Cluster 1 – Clients premium** : ce segment regroupe les clients les plus performants, avec un chiffre d'affaires élevé et une forte rentabilité. Ils représentent une cible stratégique pour l'entreprise.
- **Cluster 2 – Clients réguliers** : ces clients présentent des performances moyennes en termes de ventes et de profit. Ils constituent la base stable de l'activité commerciale.

Listing 4.11 – Mapping des segments

```
mapping = {
    0: "Non rentable",
    1: "Premium",
    2: "R gulier"
}
```

Cette segmentation permet à l'entreprise de mieux comprendre son portefeuille clients et d'adapter ses stratégies, par exemple en fidélisant les clients premium ou en améliorant la rentabilité des clients non performants.

4.2.8 Visualisation des segments clients

Afin de mieux comprendre la répartition et les caractéristiques des segments, plusieurs visualisations ont été réalisées.

4.2.8.1 Scatterplot : Segmentation des clients (Ventes vs Profit)



FIGURE 4.8 – Segmentation des clients (Ventes vs Profit)

Cette visualisation met en évidence une séparation claire entre les différents segments :

- Les **clients premium** se situent dans la zone à forte valeur, avec des ventes et des profits élevés.
- Les **clients réguliers** sont concentrés autour de valeurs moyennes, traduisant une performance stable.
- Les **clients non rentables** présentent des profits négatifs malgré des niveaux de ventes parfois importants.

Cette représentation confirme la pertinence du clustering et la bonne distinction entre les profils clients.

4.2.8.2 Graphe en barres : Comparaison des segments

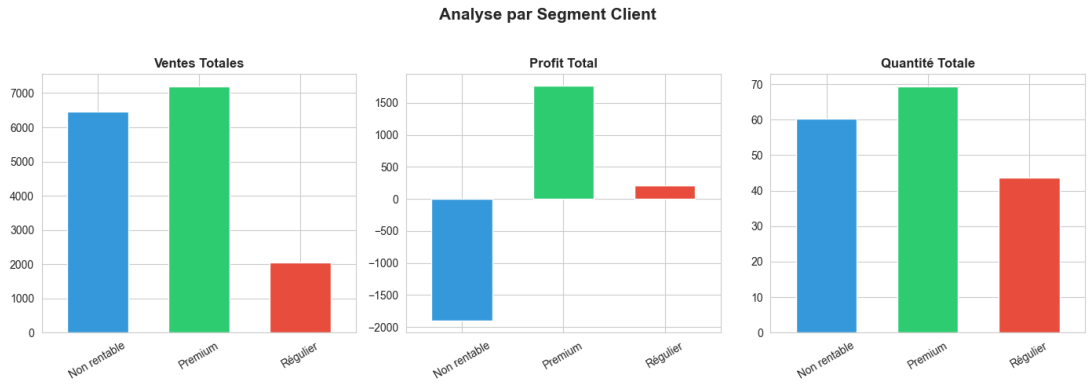


FIGURE 4.9 – Comparaison des segments selon les indicateurs clés

Le graphique met en évidence les différences de performance entre les segments :

- Les **clients premium** dominent en termes de ventes, de profit et de quantité.
- Les **clients non rentables** présentent un profit négatif malgré un volume de ventes élevé.
- Les **clients réguliers** affichent des valeurs intermédiaires sur l'ensemble des indicateurs.

Ces résultats permettent d'identifier clairement les segments les plus stratégiques et ceux nécessitant des actions correctives.

4.2.8.3 Diagramme circulaire : Répartition des segments

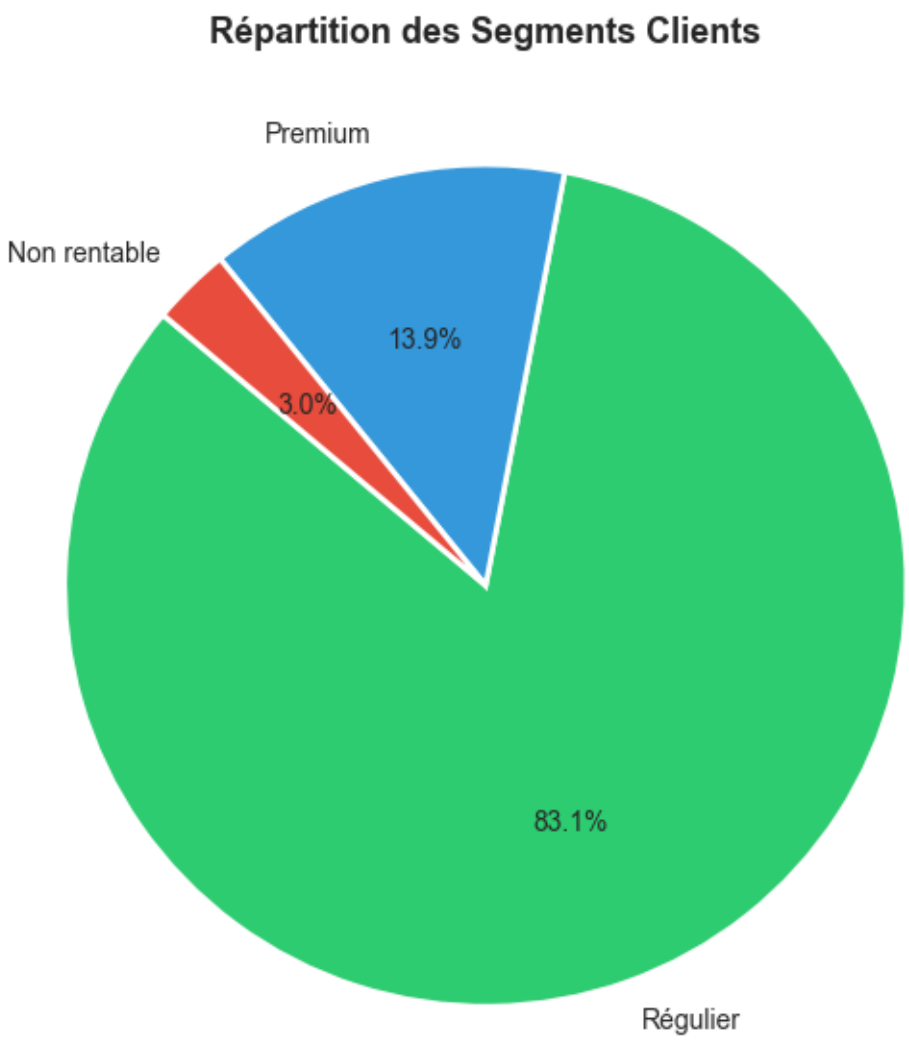


Figure 4.10 – Répartition des segments clients

La répartition des segments montre que :

- Les **clients réguliers** représentent la majorité (environ 83,1%), constituant le cœur de l'activité.

- Les **clients premium** représentent une part plus réduite (environ 13,9%), mais génèrent une forte valeur en termes de rentabilité.
- Les **clients non rentables** sont minoritaires (environ 3%), mais nécessitent une attention particulière.

Cette distribution permet d'orienter les décisions stratégiques, notamment en maintenant la satisfaction des clients réguliers, en développant la valeur des clients premium, et en améliorant la rentabilité des clients non performants.

Conclusion

Ce chapitre a permis de mettre en œuvre des techniques d'intelligence artificielle pour enrichir l'analyse des données. La prévision des ventes a montré la capacité du modèle à anticiper les tendances futures, tandis que la segmentation des clients a permis d'identifier des profils distincts et exploitables. Ces résultats apportent une réelle valeur ajoutée au tableau de bord en facilitant la prise de décision et l'optimisation des stratégies commerciales.

Conclusion Générale

Ce projet a permis de concevoir et de mettre en œuvre un système décisionnel complet basé sur un Data Warehouse, dans le but d'améliorer le suivi des performances d'une entreprise et de faciliter la prise de décision.

L'approche adoptée a consisté à extraire les données à partir d'un fichier CSV, puis à les transformer et les charger à travers un processus ETL afin de les préparer pour l'analyse. Ces données ont ensuite été structurées selon un modèle multidimensionnel reposant sur des tables de faits et de dimensions. Cette organisation a permis de garantir une meilleure cohérence des données, ainsi qu'une exploitation efficace à des fins analytiques.

La mise en place des tableaux de bord interactifs sous Power BI a permis de transformer les données en informations exploitables, offrant une visualisation claire et synthétique des indicateurs clés de performance liés aux processus métiers principaux, notamment les ventes, les clients et la livraison. Ces dashboards facilitent l'analyse, l'identification des tendances et le suivi de l'activité de manière intuitive et dynamique.

Par ailleurs, l'intégration d'une composante d'intelligence artificielle a enrichi le système décisionnel en apportant une dimension analytique avancée. La prévision du chiffre d'affaires à court terme a permis d'anticiper les tendances futures, tandis que la segmentation des clients à l'aide de l'algorithme K-Means a permis d'identifier des profils distincts et exploitables pour l'optimisation des stratégies commerciales.

Ainsi, ce projet a permis de mettre en pratique les concepts fondamentaux du décisionnel, allant de la préparation des données à leur valorisation à travers la visualisation et l'analyse avancée. Il constitue une solution cohérente et efficace pour améliorer la compréhension des données et soutenir la prise de décision stratégique au sein de l'entreprise.